Visualización de datos en R

Visualizar distribuciones

Mario Morales

04/03/2026

Contenido I

1. Visualización de distribuciones
2. Variables categóricas
3. Variables numéricas
4. Dos variables

Section 1

Visualización de distribuciones

Introducción

La forma de visualizar la distribución de una variable depende del tipo de variable:

- categórica
- numérica.

Section 2

Variables categóricas

Una variable categórica

- Una variable categórica (también denominada variable cualitativa) es aquella cuyas unidades de observación se clasifican en un conjunto de categorías o clases mutuamente excluyentes y colectivamente exhaustivas, las cuales no poseen una magnitud numérica intrínseca por naturaleza.
- Para examinar la distribución de una variable categórica, puede utilizar un gráfico de barras.
- La altura de las barras muestra cuántas observaciones ocurrieron con cada valor `x`.

Carga de librería

```
library(tidyverse)
library(palmerpenguins)
```

```
ggplot(penguins, aes(x = species)) + geom_bar()
```

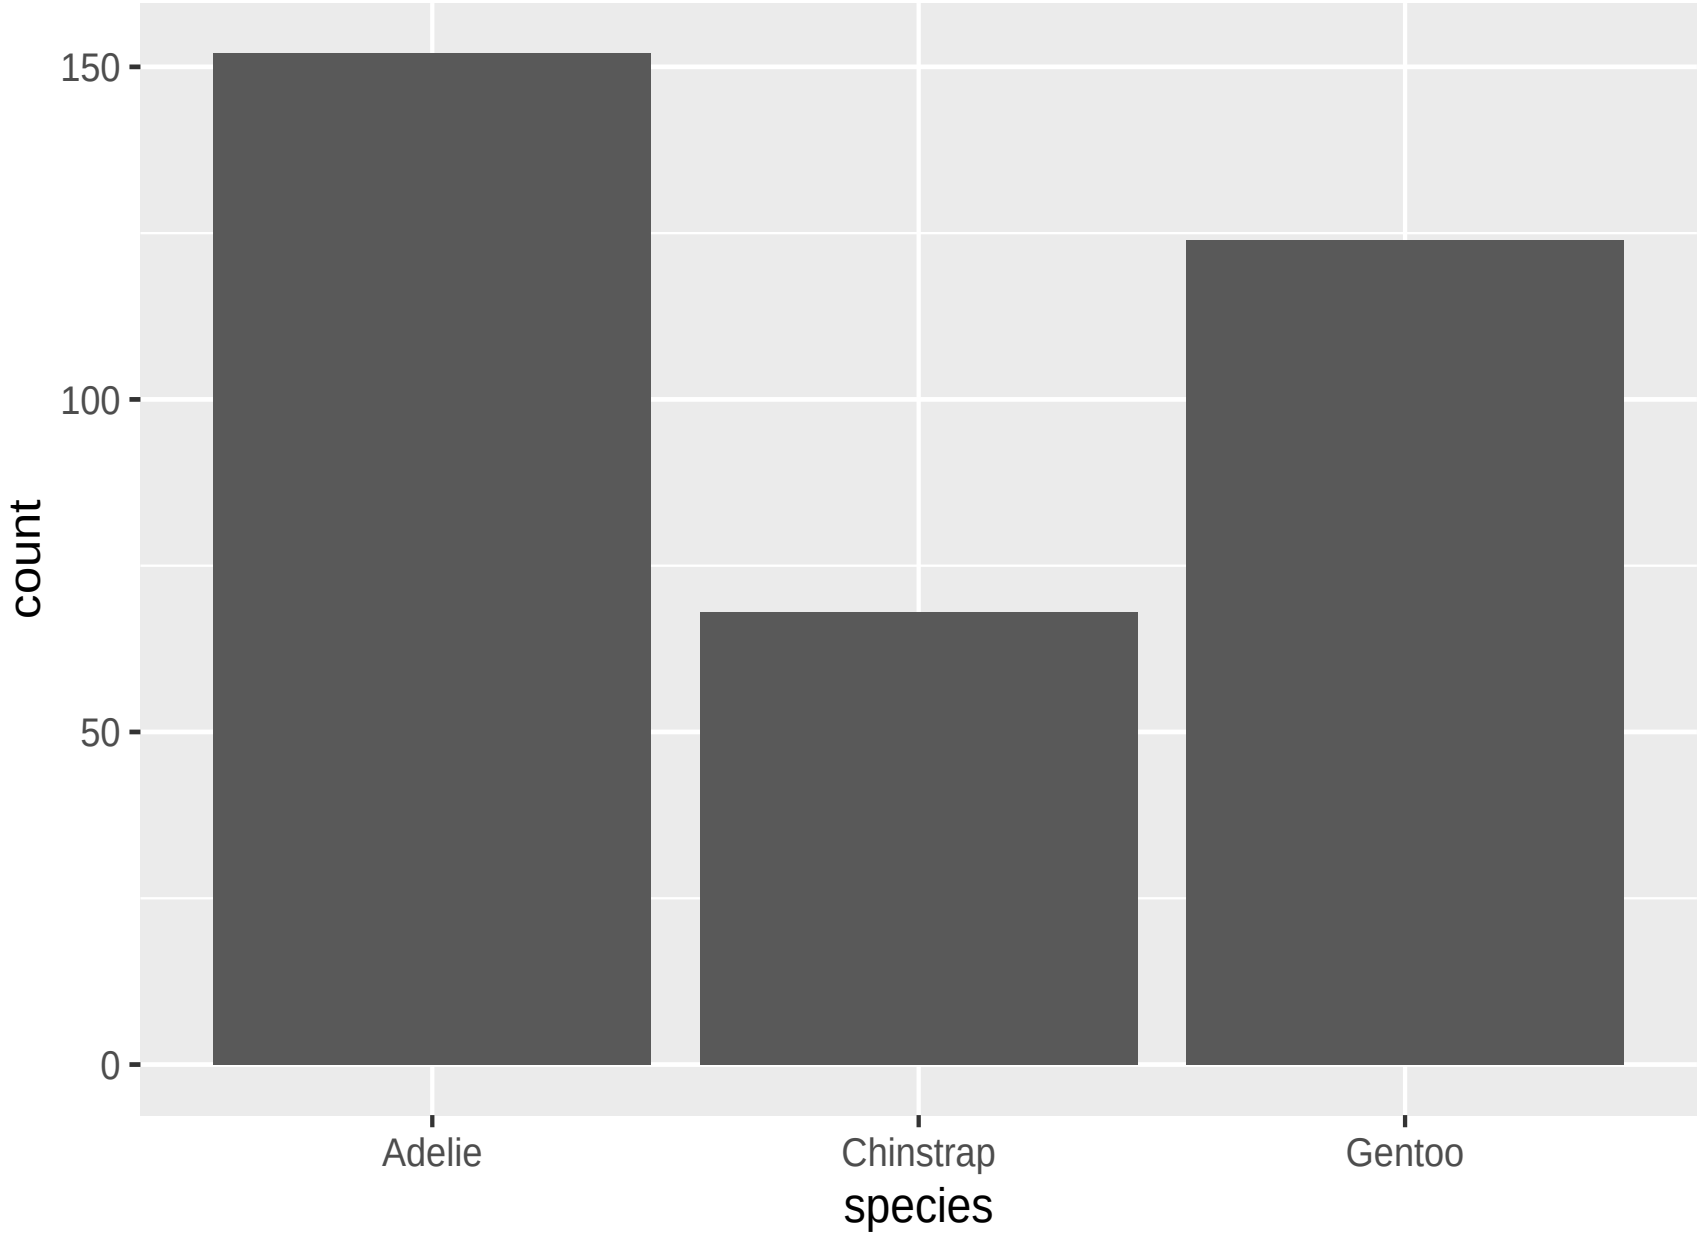
150
100
50
0
count
Adelie
Chinstrap
Gentoo
species

Ordenar por la frecuencia

En los gráficos de barras de variables categóricas con niveles no ordenados, como la especie de los pingüinos, a menudo es preferible reordenar las barras en función de sus frecuencias.

Para ello es necesario transformar la variable en un factor y luego reordenar los niveles de ese factor.

Ordenar barras por frecuencia

```
ggplot(penguins, aes(x=fct_infreq(species))) + geom_bar()
```

Barras ordenadas

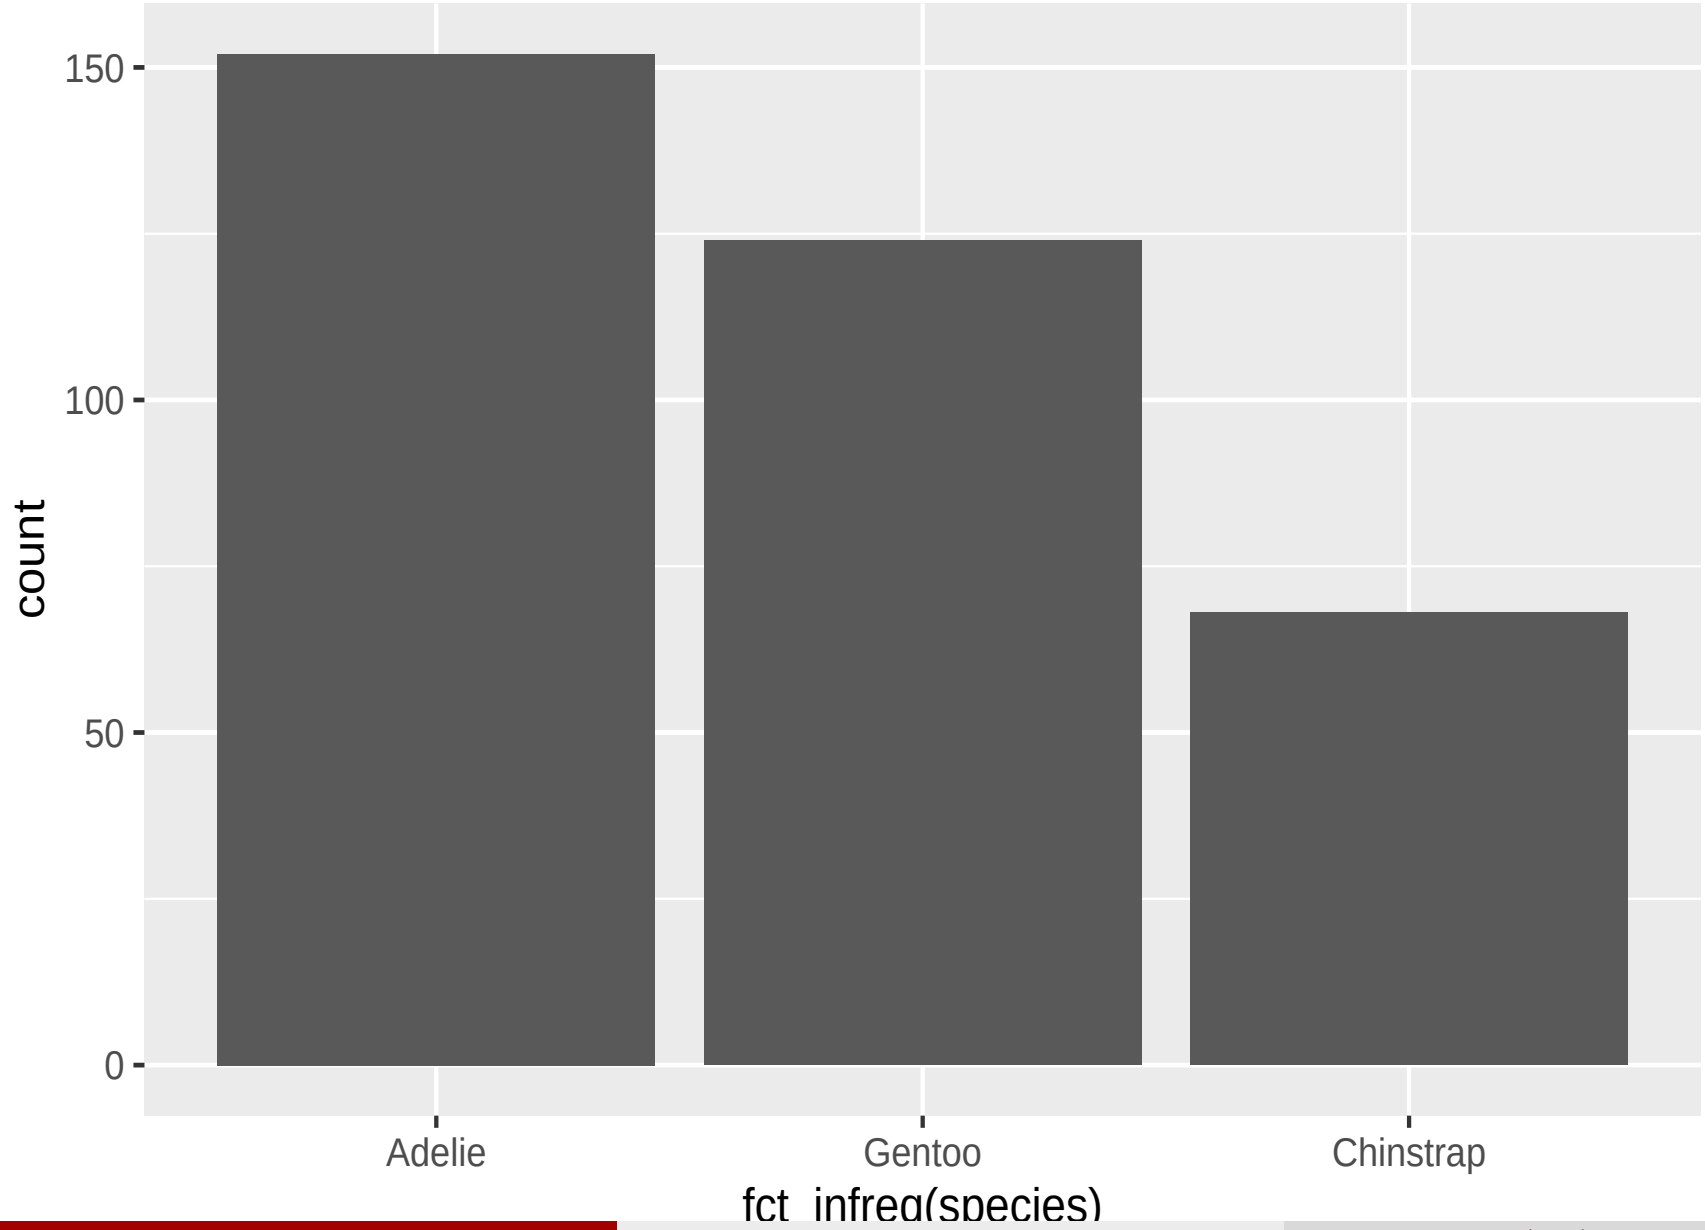

Color de las barras

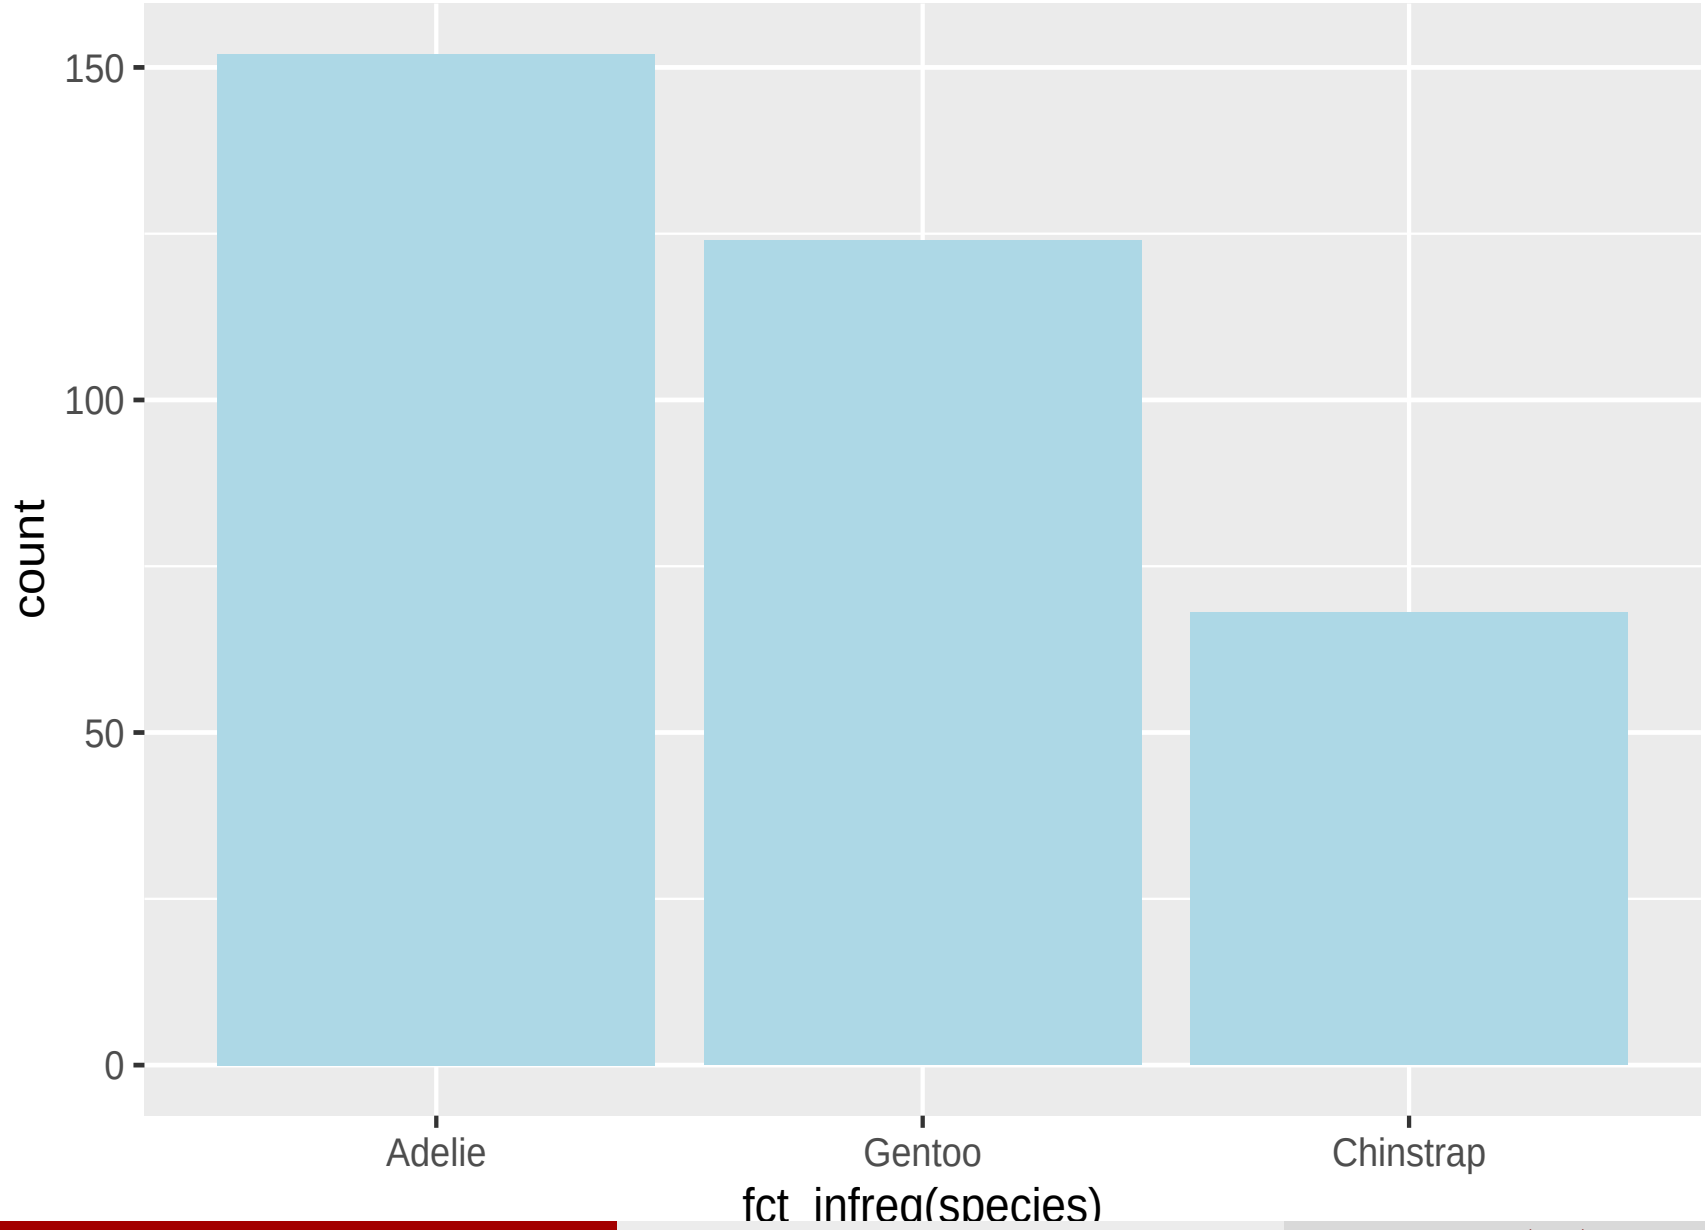

Color de las barras

```
ggplot(penguins, aes(x=fct_infreq(species)))
+ geom_bar(fill="lightblue")
```

Color de borde de las barras

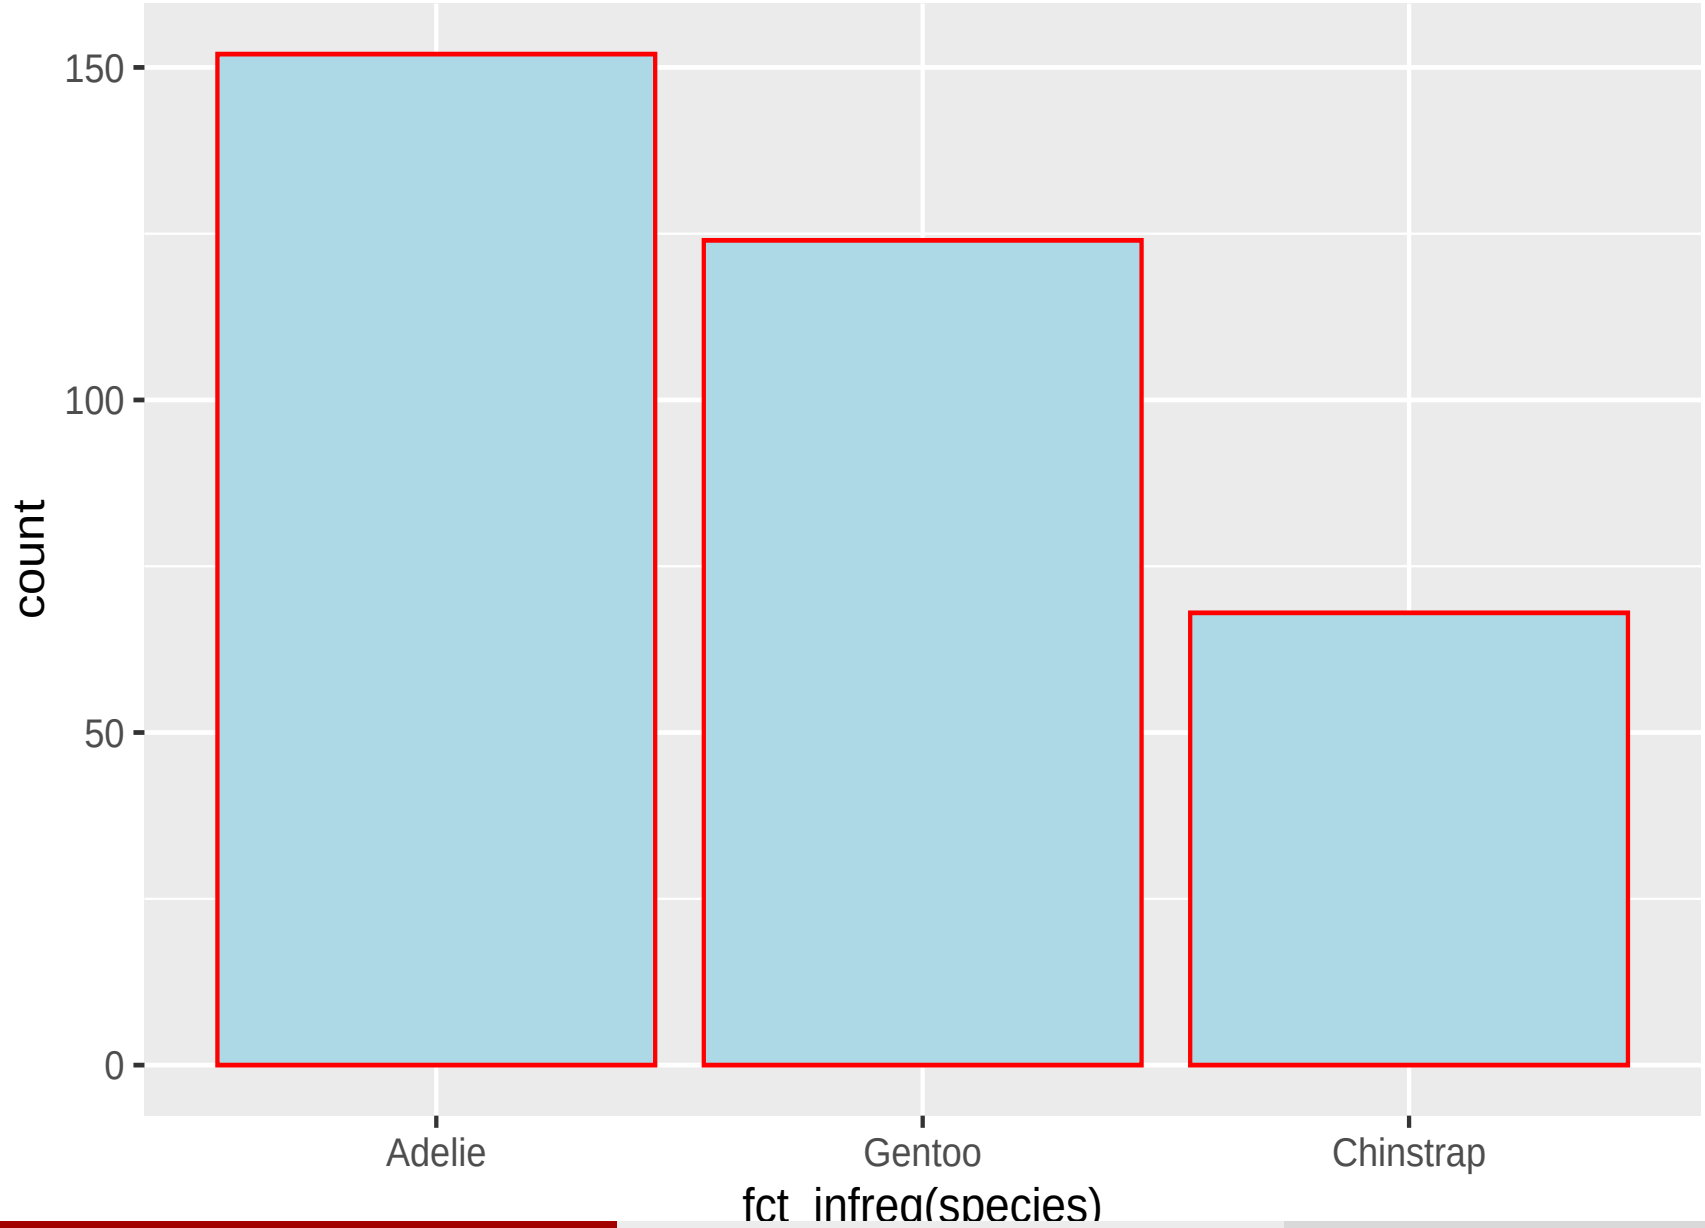

Color de borde de las barras

```
ggplot(penguins, aes(x=fct_infreq(species)))
+ geom_bar(fill="lightblue",color="red")
```

Frecuencia sobre las barras

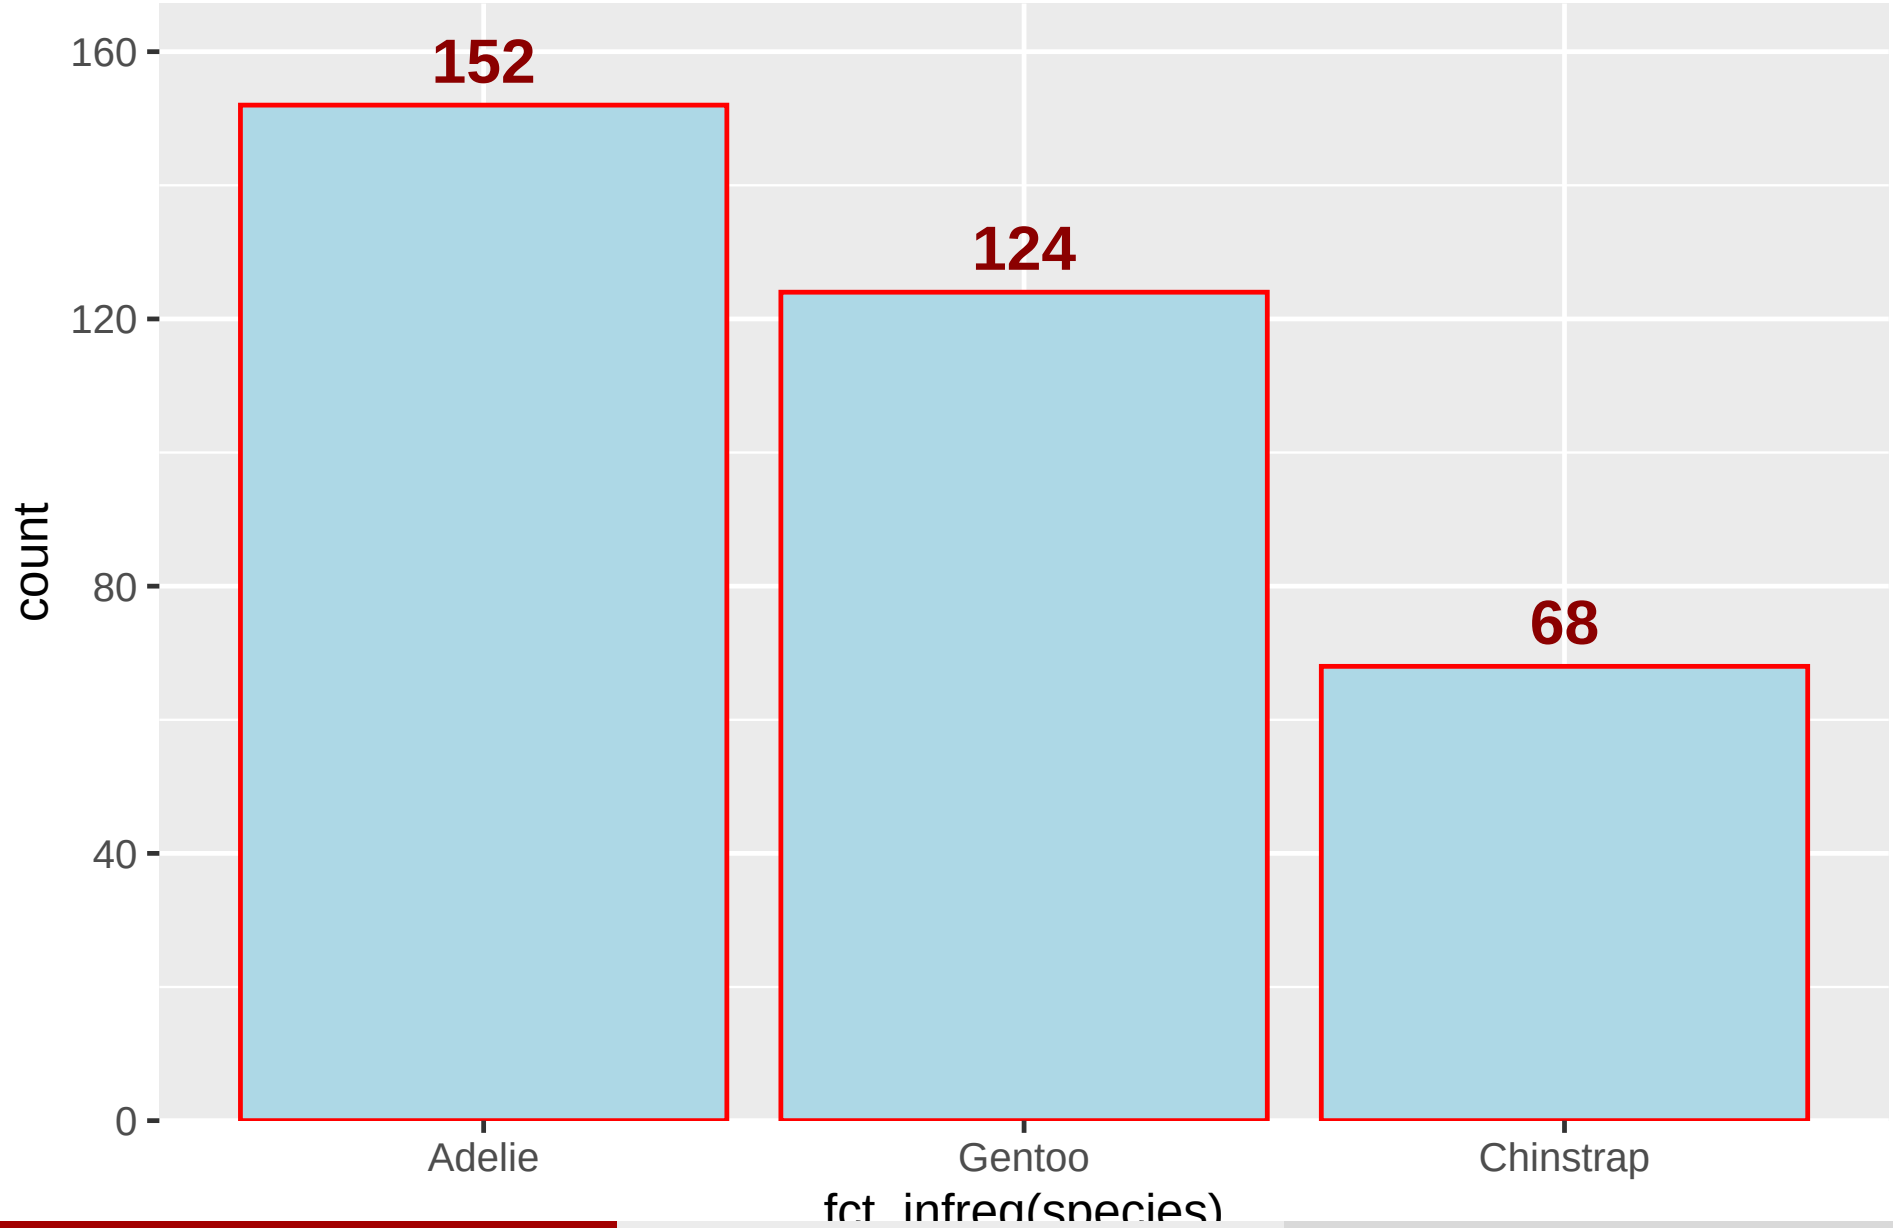

```r
ggplot(penguins, aes(x=fct_infreq(species))) +
  geom_bar(fill="lightblue",color="red")
  + geom_text(
    stat = "count",
    aes(label = after_stat(count)),                    ①
    vjust = -0.5,                                      ②
    color = "darkred",                                 ③
    fontface = "bold",                                 ④
    size = 5) +                                        ⑤
  scale_y_continuous(expand = expansion(mult = c(0, 0.1))) ⑥
```

① Le pedimos que use el conteo calculado
② Ajuste vertical: -0.5 lo pone "arriba" de la barra
③ Color para que combine con el borde
④ En negrita para mayor claridad
⑤ Tamaño del texto
⑥ Importante: aumentar el límite de Y para que el número no se corte

Porcentajes en cada barra

```
library(scales) # Muy útil para dar formato de % automáticamen
ggplot(penguins, aes(x = species)) +
  geom_bar(fill = "steelblue", color = "black") +
  geom_text(
    stat = "count",
    aes(label = after_stat(paste0(round(count / sum(count) * 1
    vjust = -0.5,        # Lo sitúa justo encima de la barra
    size = 4.5,
    fontface = "bold"
  ) +
  # Añadimos un poco de espacio extra en el eje Y
  scale_y_continuous(expand = expansion(mult = c(0, 0.15))) +
  labs(
    title = "Distribución Porcentual por Especie",
    x = "Especie de Pingüino",
    y = "Frecuencia Absoluta (n_i)"
```

Section 3

Variables numéricas

Una variable numérica

- Una variable numérica es aquella que expresa una característica de la unidad de observación mediante un valor escalar perteneciente al conjunto de los números reales ($\mathbb{R}$).
- Las variables numéricas pueden ser continuas o discretas.
- Una visualización comúnmente utilizada para distribuciones de variables continuas es el histograma.
- Un histograma divide el eje `x` en intervalos o segmentos igualmente espaciados y luego utiliza la altura de una barra para mostrar la cantidad de observaciones que caen en cada intervalo.

Histograma

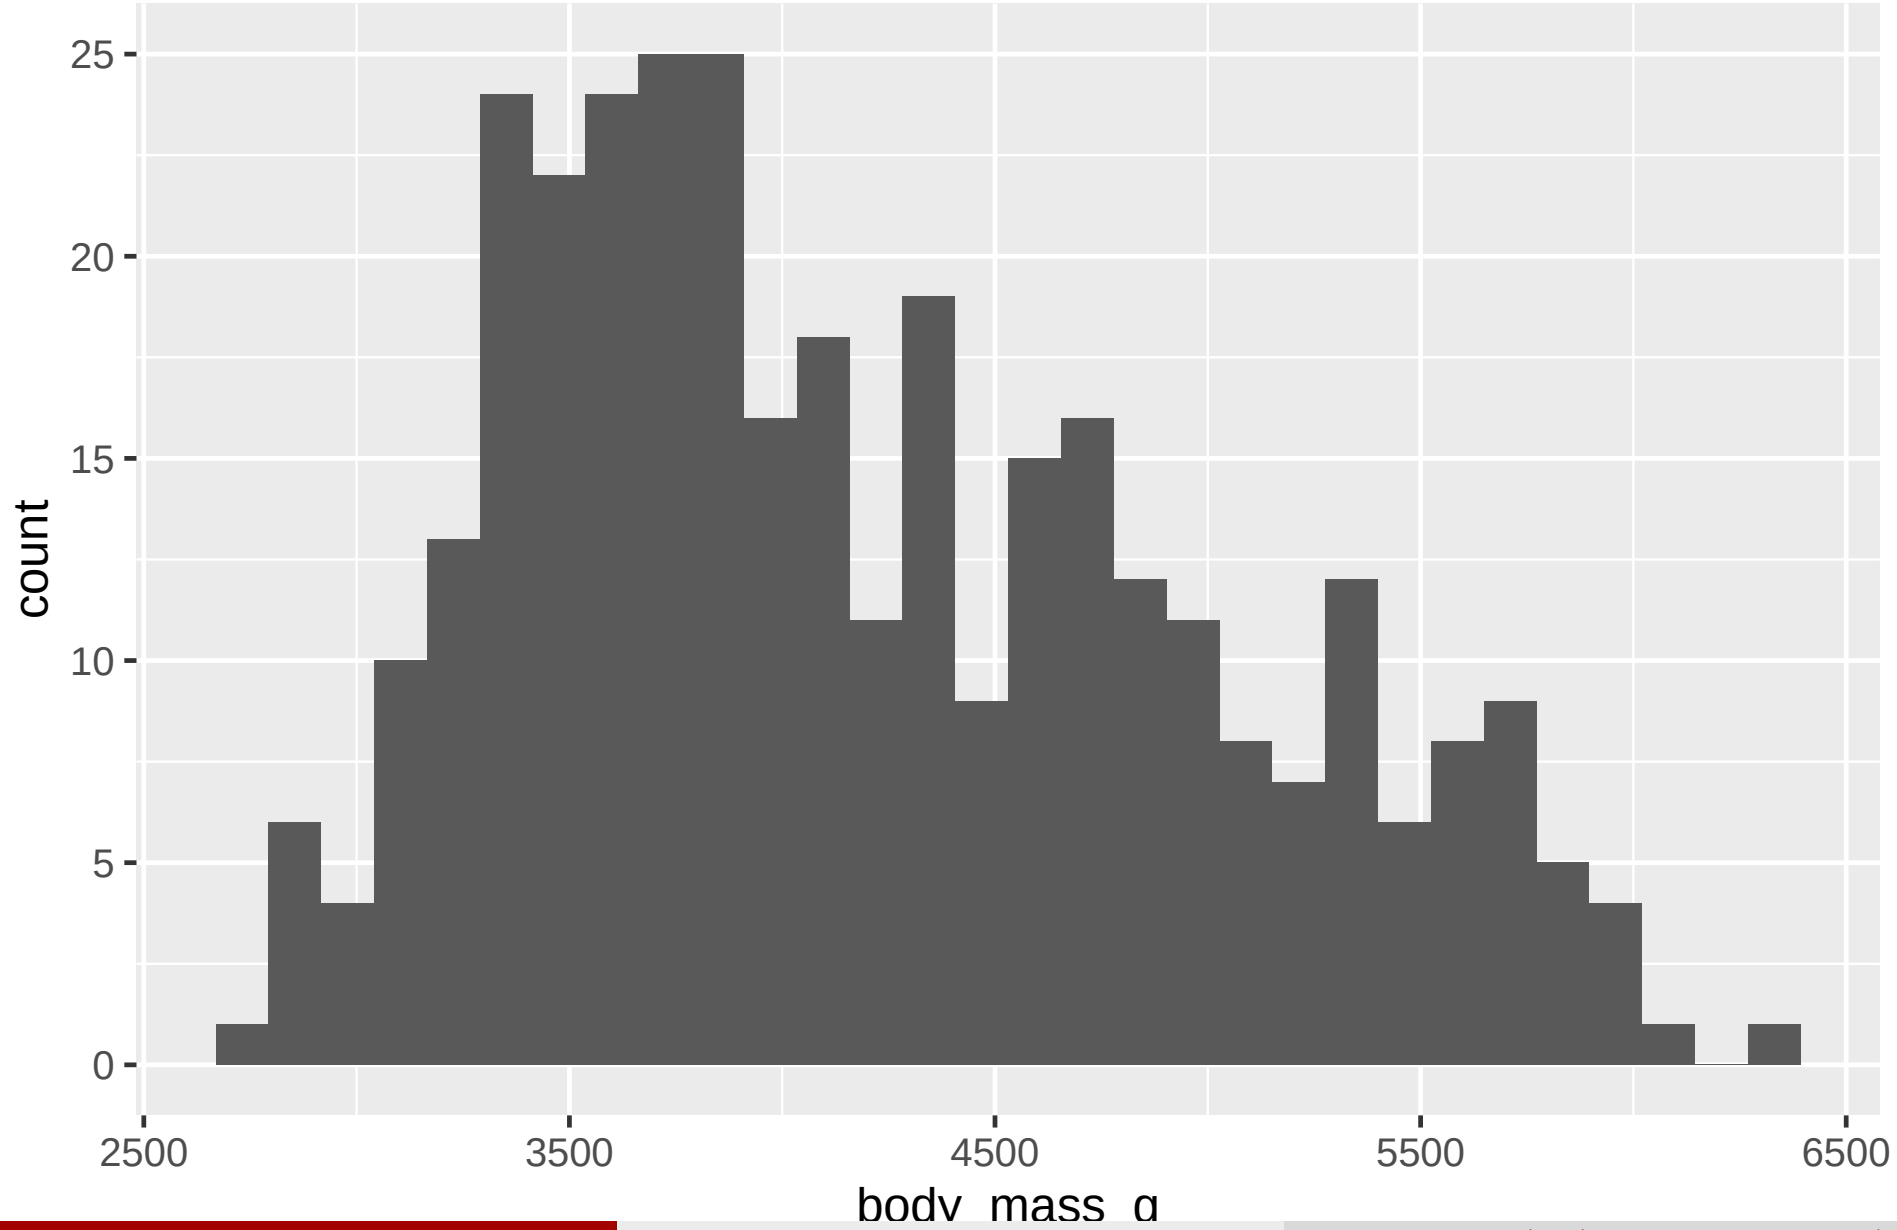

Histograma, código ggplot2

```
ggplot(penguins, aes(x = body_mass_g)) + geom_histogram()
```

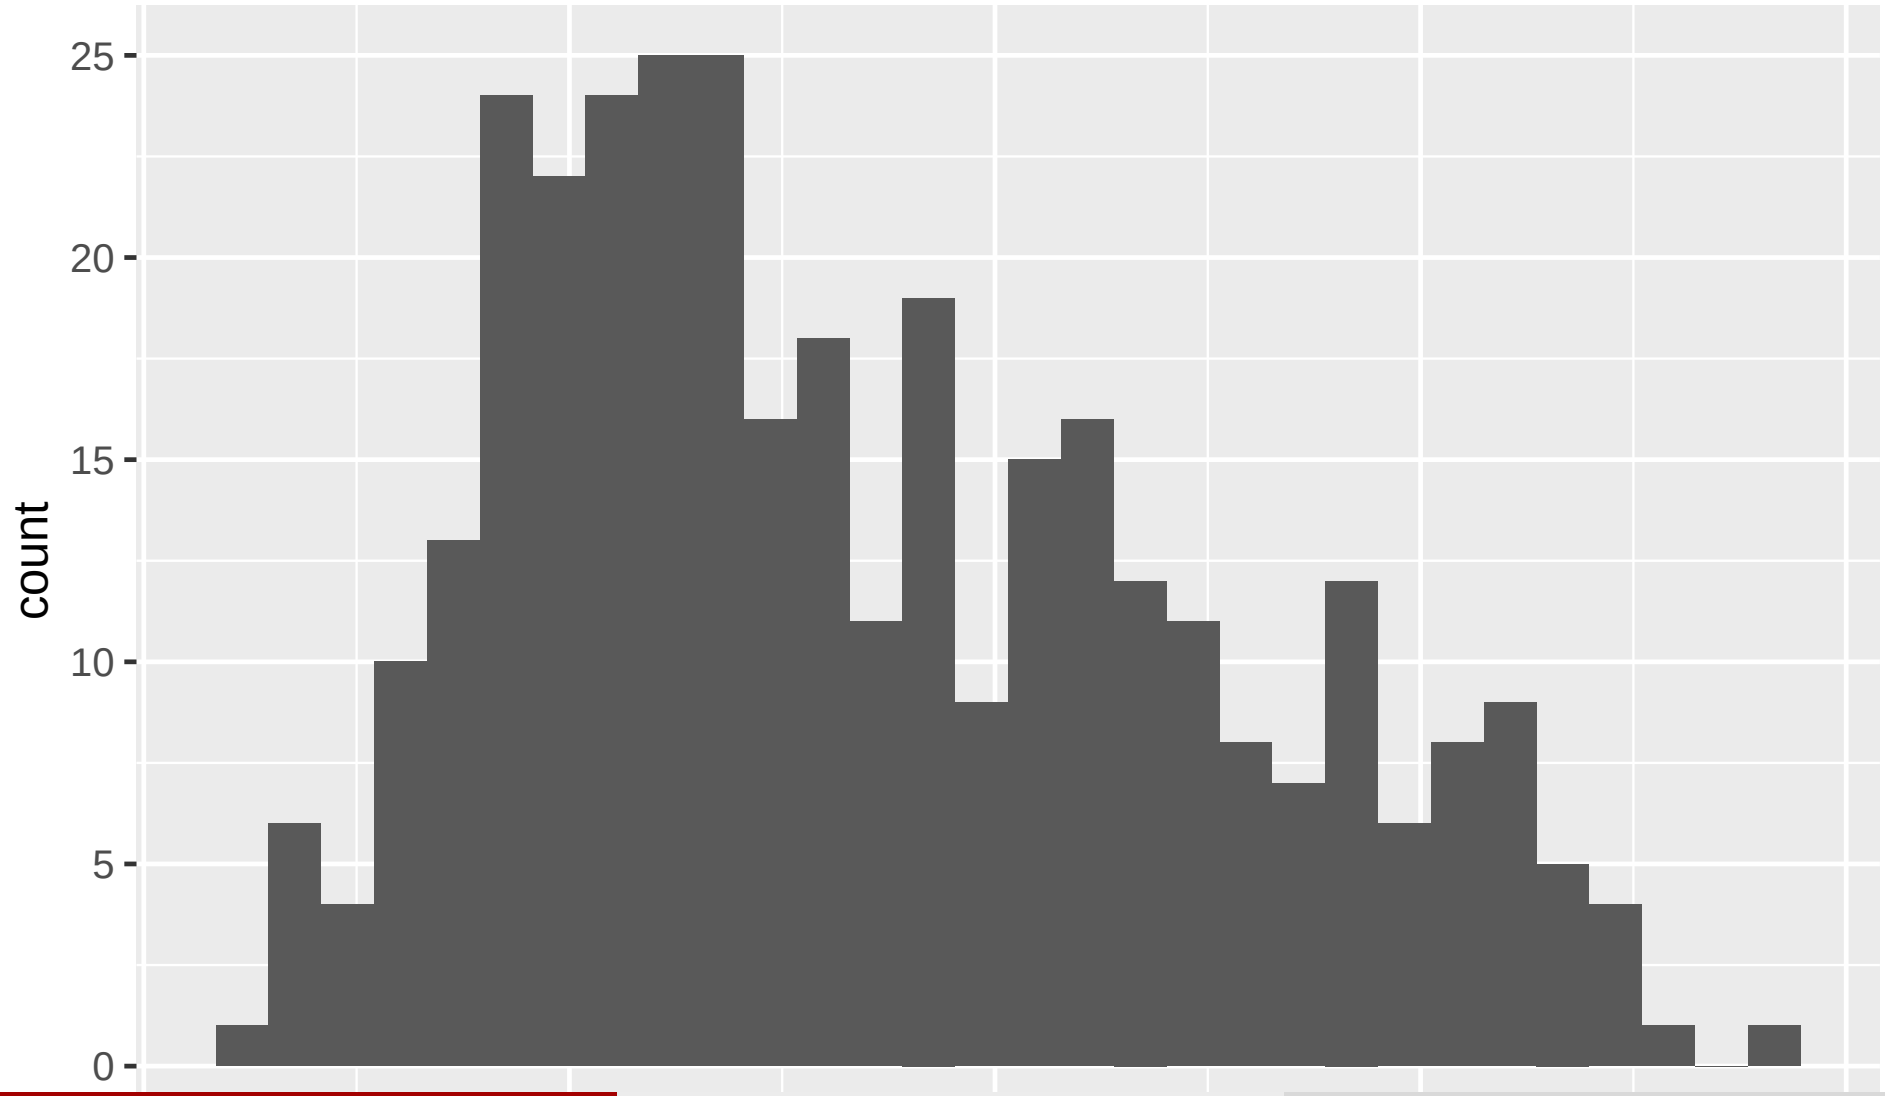

Histograma

Podemos controlar el ancho de los intervalos de clase con `binwidth`

```
ggplot(penguins, aes(x = body_mass_g))
  + geom_histogram(binwidth = 200)
```

Histograma

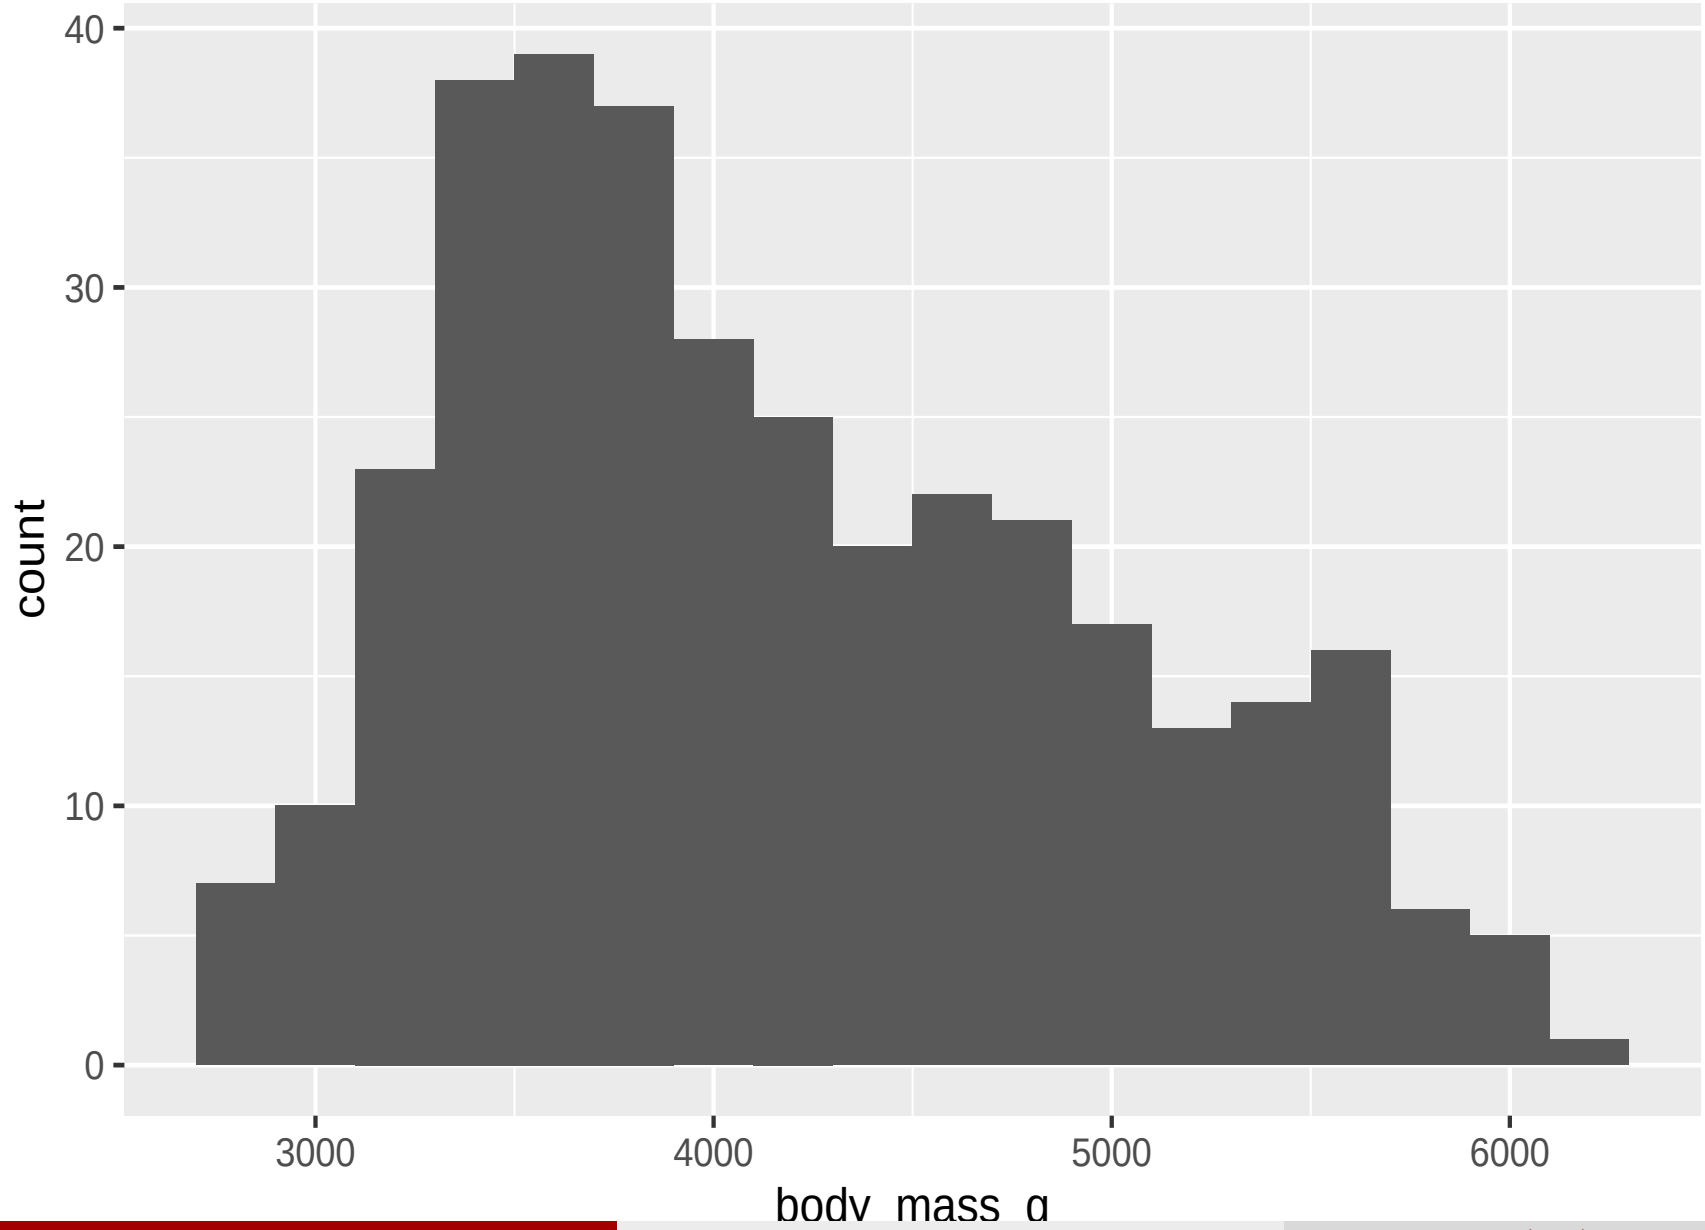

Calcular el binwidth

```
# Número de datos
n=length(penguins$body_mass_g)
# Número de intervalos
K=ceiling(1+3.3*log10(n))
# Rango
R=diff(range(penguins$body_mass_g,na.rm = TRUE))
# Ancho de los intervalos de clase (binwidth)
A=R/K
paste("Ancho=",A,"Rango=",R,"Número de int=",K)
```

```
[1] "Ancho= 360 Rango= 3600 Número de int= 10"
```

```
ggplot(penguins, aes(x = body_mass_g))
  + geom_histogram(binwidth = A)
```

Histograma

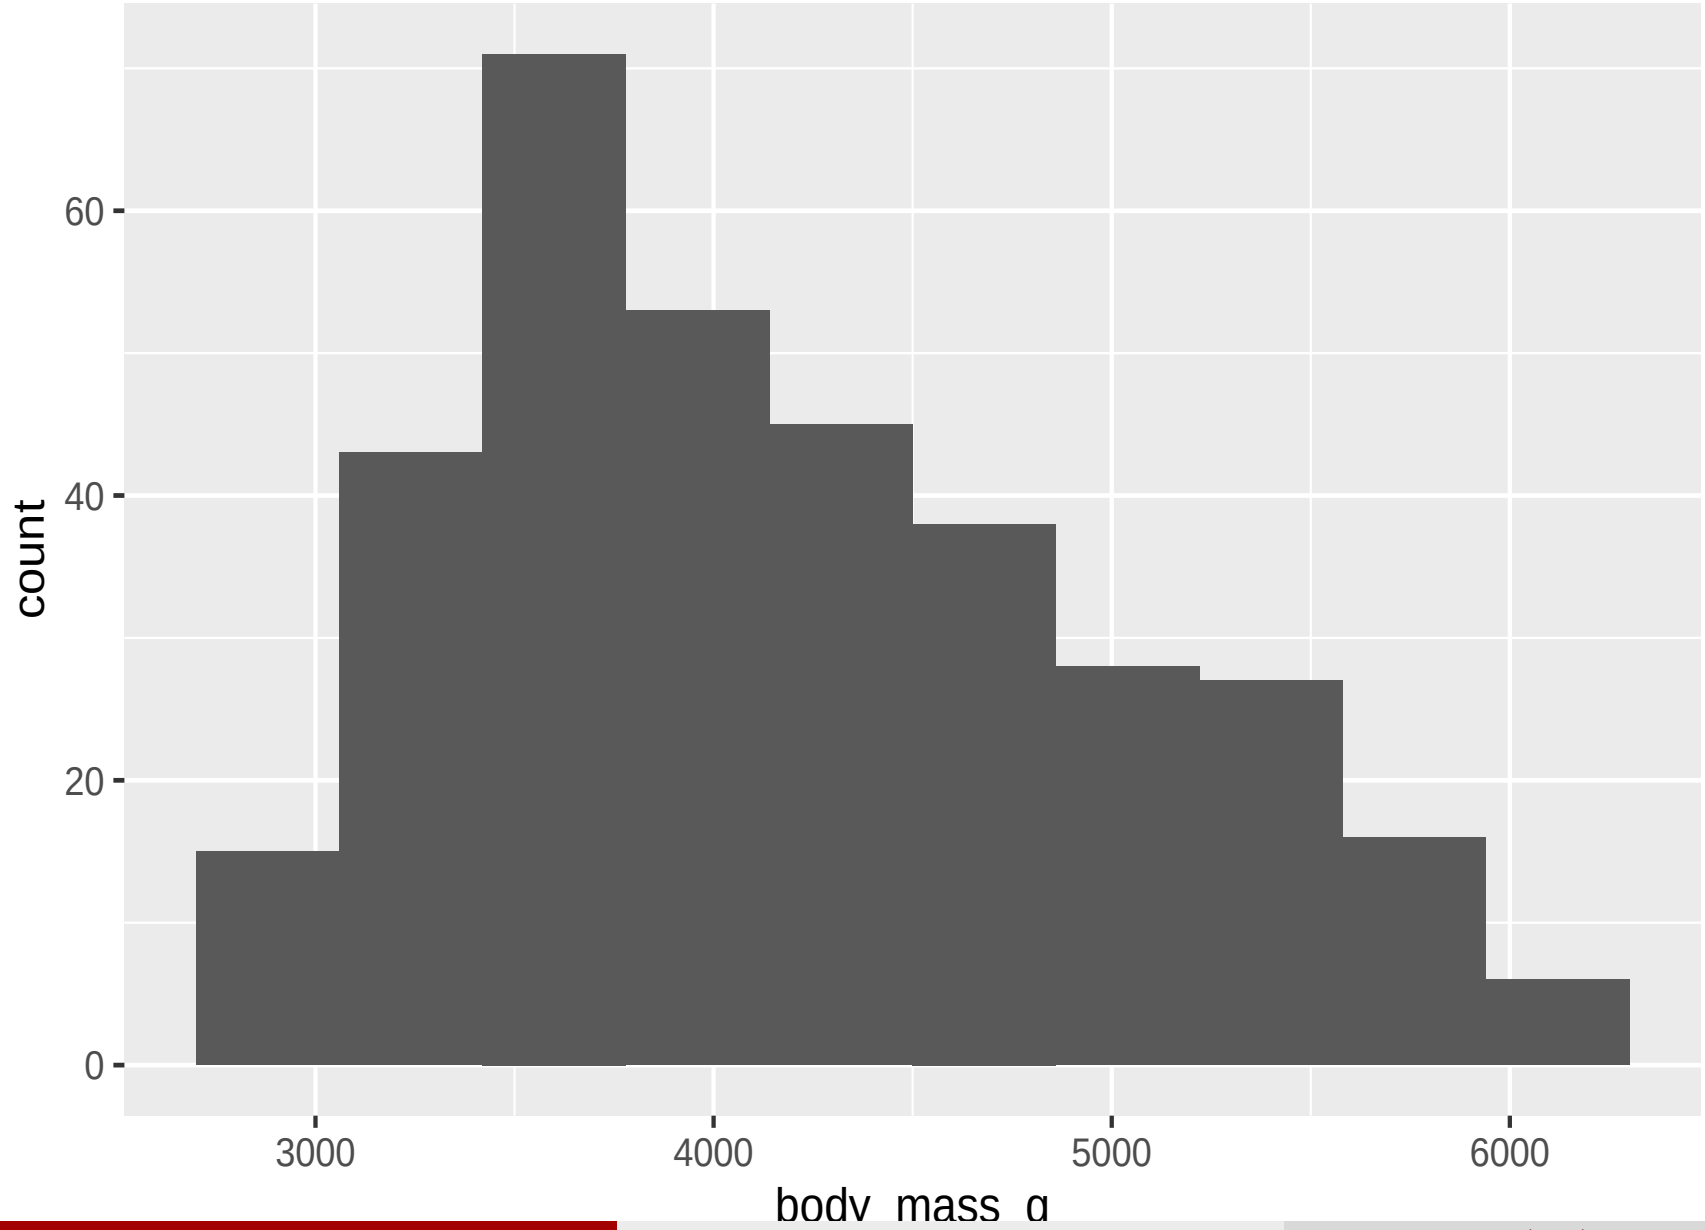

Histograma

```
ggplot(penguins, aes(x = body_mass_g))
  + geom_histogram(bins=K)
```

Histograma

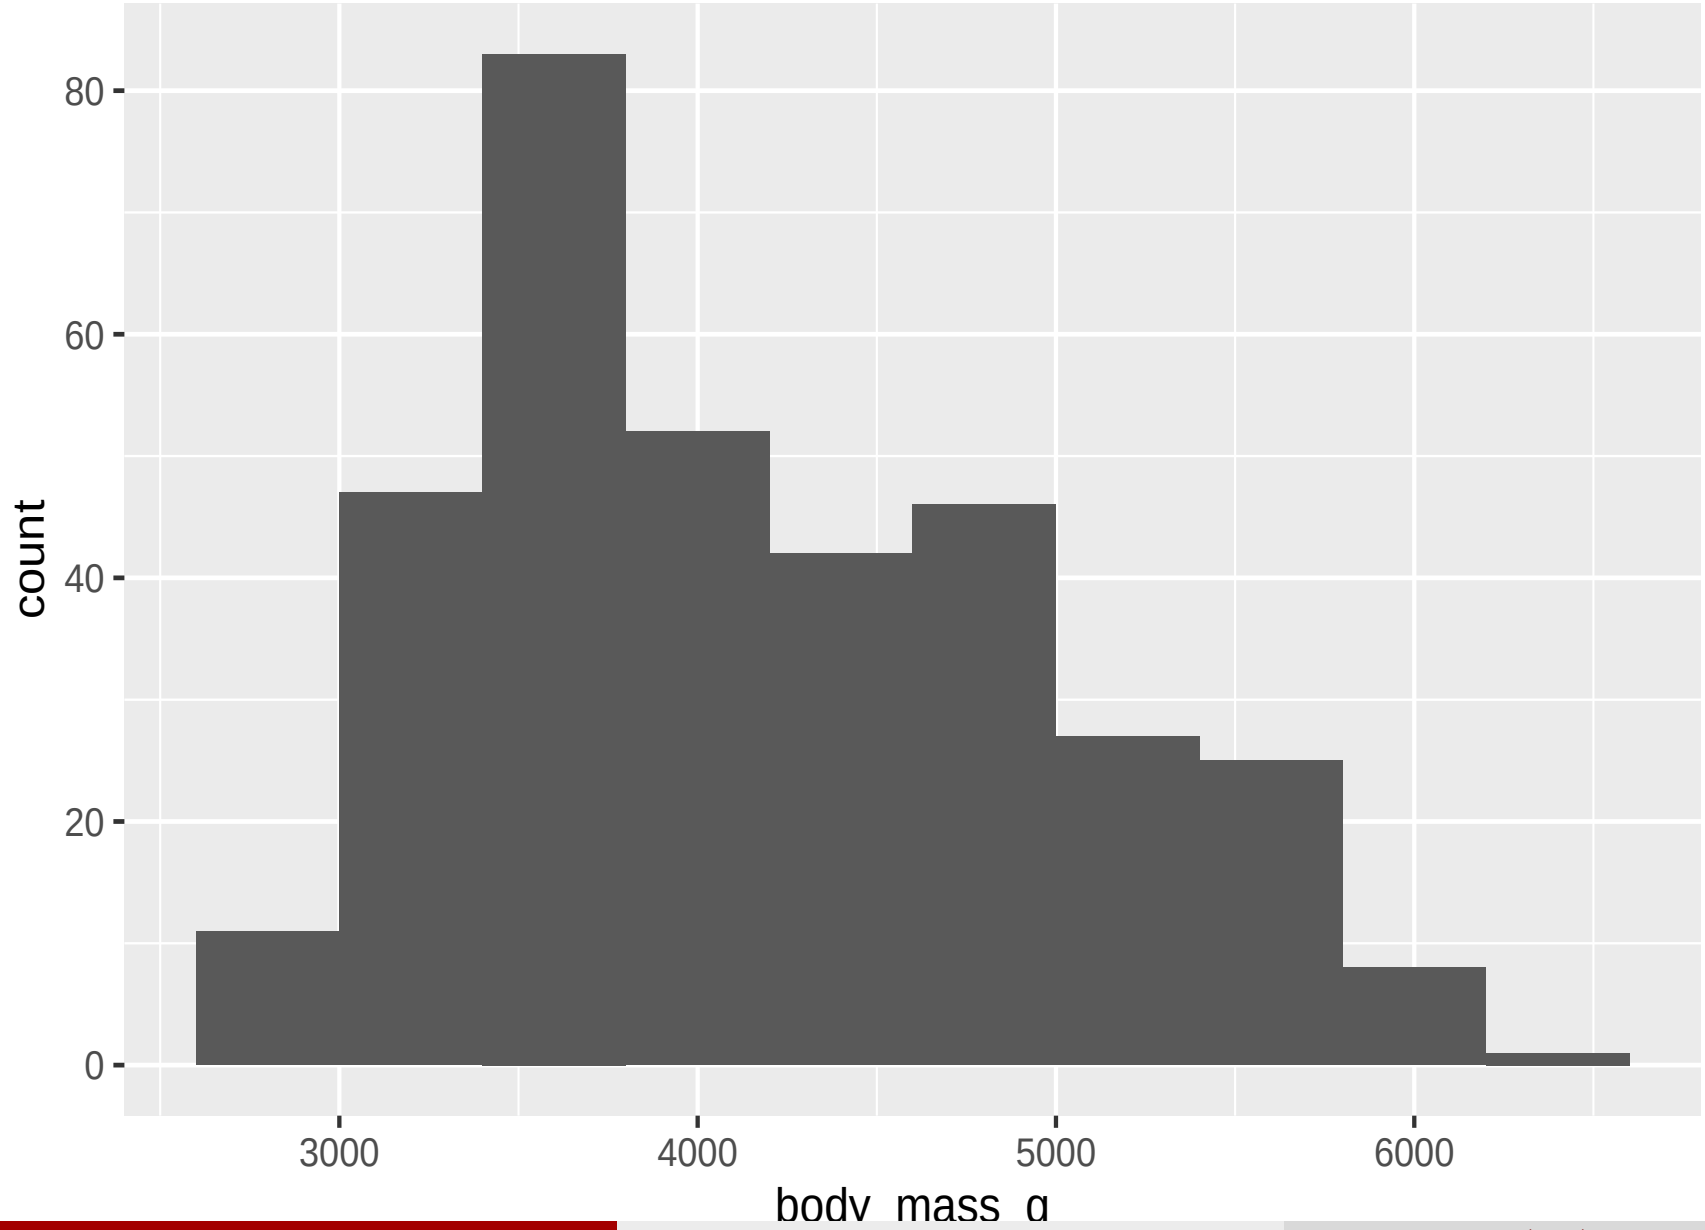

Gráfico de densidad

- Una visualización alternativa para distribuciones de variables numéricas es un gráfico de densidad.
- Un gráfico de densidad es una versión suavizada de un histograma y una alternativa práctica, particularmente para datos continuos que provienen de una distribución suave subyacente.
- Imagínese un histograma hecho con bloques de madera.
- Luego imagina que dejas caer sobre él un hilo de espagueti cocido.
- La forma que adoptarán los espaguetis al colocarlos sobre los bloques puede considerarse como la forma de la curva de densidad.
- Muestra menos detalles que un histograma, pero puede facilitar la comprensión rápida de la forma de la distribución, particularmente con respecto a los modas y la asimetría.

Gráfico de densidad

```
ggplot(penguins, aes(x = body_mass_g)) + geom_density()
```

Gráfico de densidad

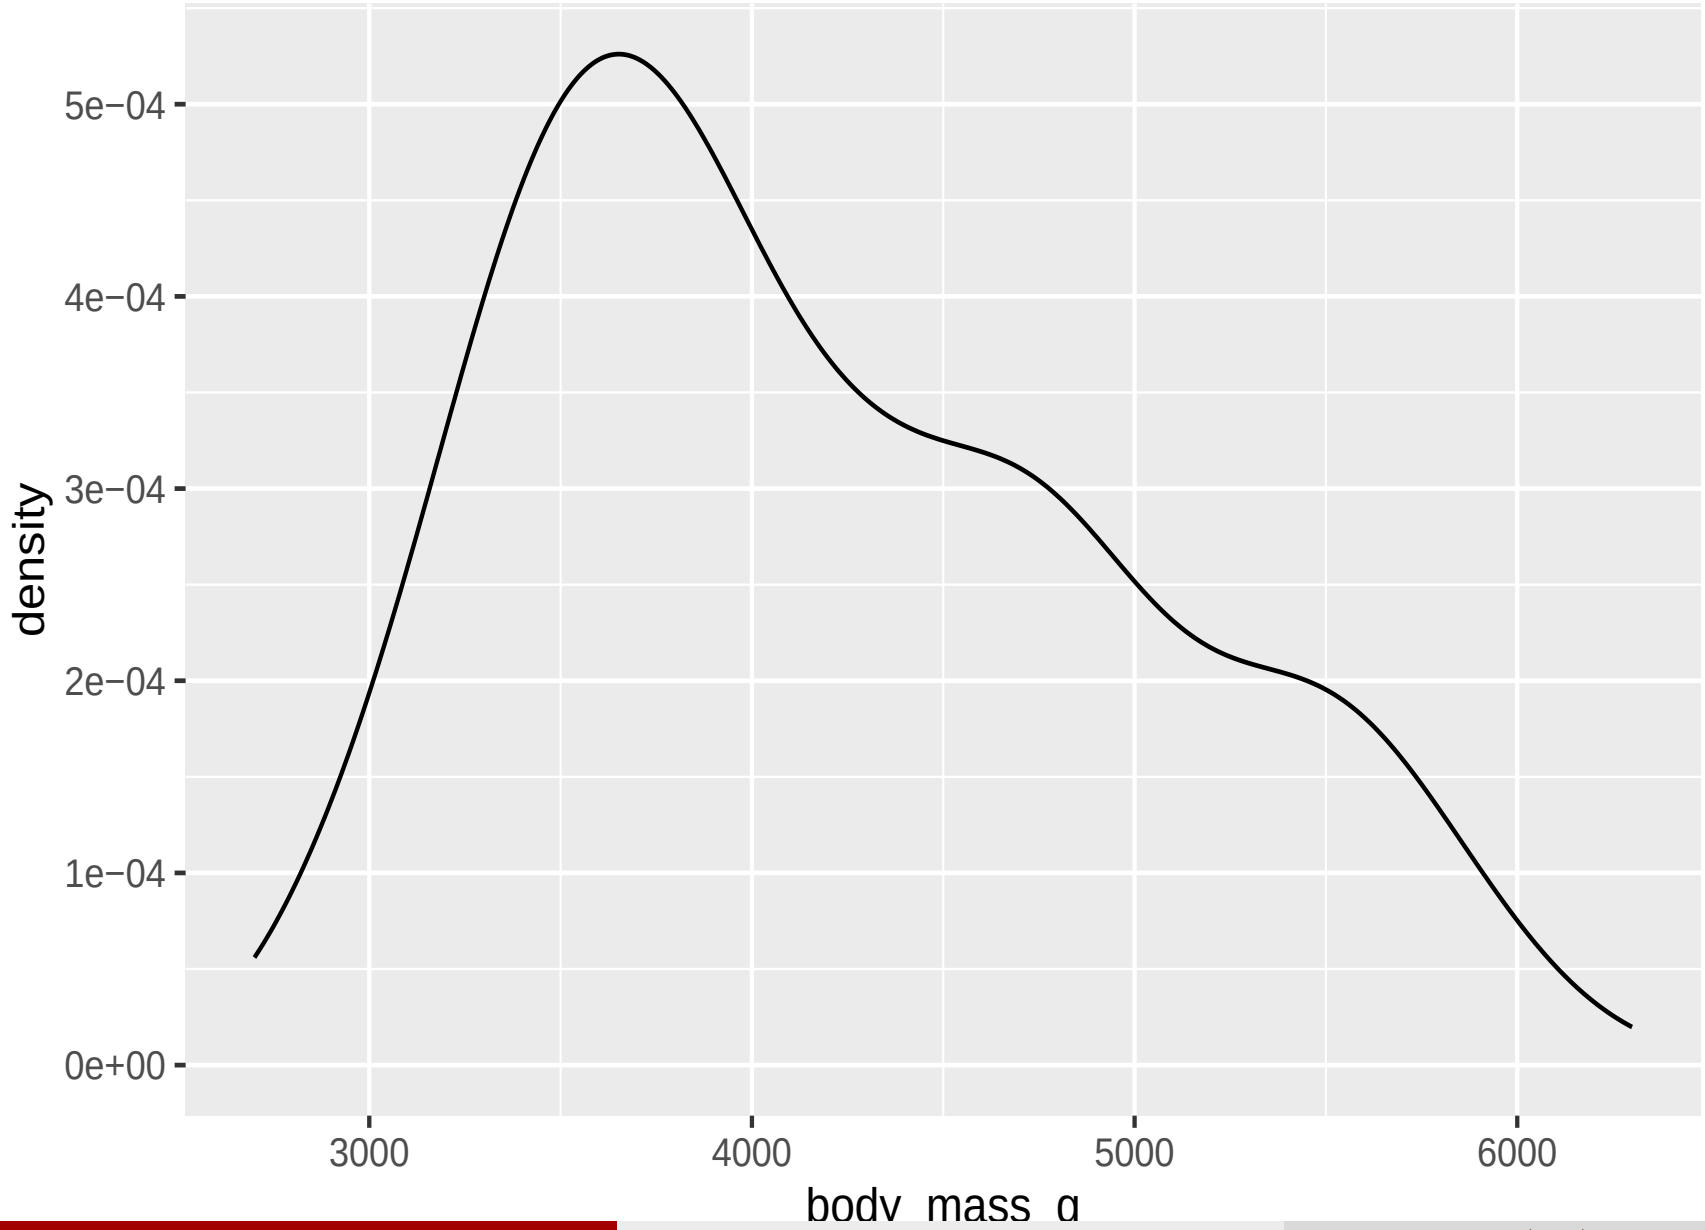

Ejercicios I

- Haz un diagrama de barras de especies de pingüinos, donde asignas especies a la estética y. ¿En qué es diferente este gráfico?
- ¿En qué se diferencian los dos gráficos siguientes? ¿Qué estética, color o relleno, es más útil para cambiar el color de las barras?

Ejercicios II

```
ggplot(penguins, aes(x = species))
 + geom_bar(color = "red")
ggplot(penguins, aes(x = species))
   + geom_bar(fill = "red")
```

- ¿Qué hace el argumento `bins` en `geom_histogram()`?
- Realice un histograma de la variable `carat` en el conjunto de datos `diamonds` que está disponible cuando carga el paquete `tidyverse`. Experimente con diferentes valores de ancho de banda. ¿Qué valor revela los patrones más interesantes?

Section 4

Dos variables

Visualizando relaciones

- Para visualizar una relación necesitamos tener al menos dos variables asignadas a la estética de un gráfico.
- En las siguientes secciones aprenderá acerca de los gráficos comúnmente utilizados para visualizar relaciones entre dos o más variables y las geometrías utilizadas para crearlas.

Una variable numérica y la otra categórica

- Podemos utilizar diagramas de caja uno al lado del otro.
- Un diagrama de caja es un tipo de representación visual de las medidas de posición (percentiles) que describen una distribución.
- También es útil para identificar posibles valores atípicos.

El boxplot consta de ...

- Un cuadro que indica el rango de la mitad central de los datos, una distancia conocida como rango intercuartil (RIC), que se extiende desde el percentil 25 de la distribución hasta el percentil 75.
- En el medio de la caja hay una línea que muestra la mediana, es decir, el percentil 50, de la distribución.
- Estas tres líneas le dan una idea de la dispersión de la distribución y de si la distribución es simétrica respecto de la mediana o está sesgada hacia un lado.
- Puntos que muestran observaciones que caen más de 1.5 veces el RIQ desde cualquier borde de la caja. Estos puntos periféricos son inusuales, por lo que se representan individualmente.
- Una línea (o bigote) que se extiende desde cada extremo de la caja y va hasta el punto no atípico más lejano de la distribución.

Boxplot de la masa corporal por especie

Echemos un vistazo a la distribución de la masa corporal por especie usando `geom_boxplot()`:

```
ggplot(penguins,aes(x =species,y= body_mass_g))
  + geom_boxplot()
```

Boxplot de la masa corporal por especie

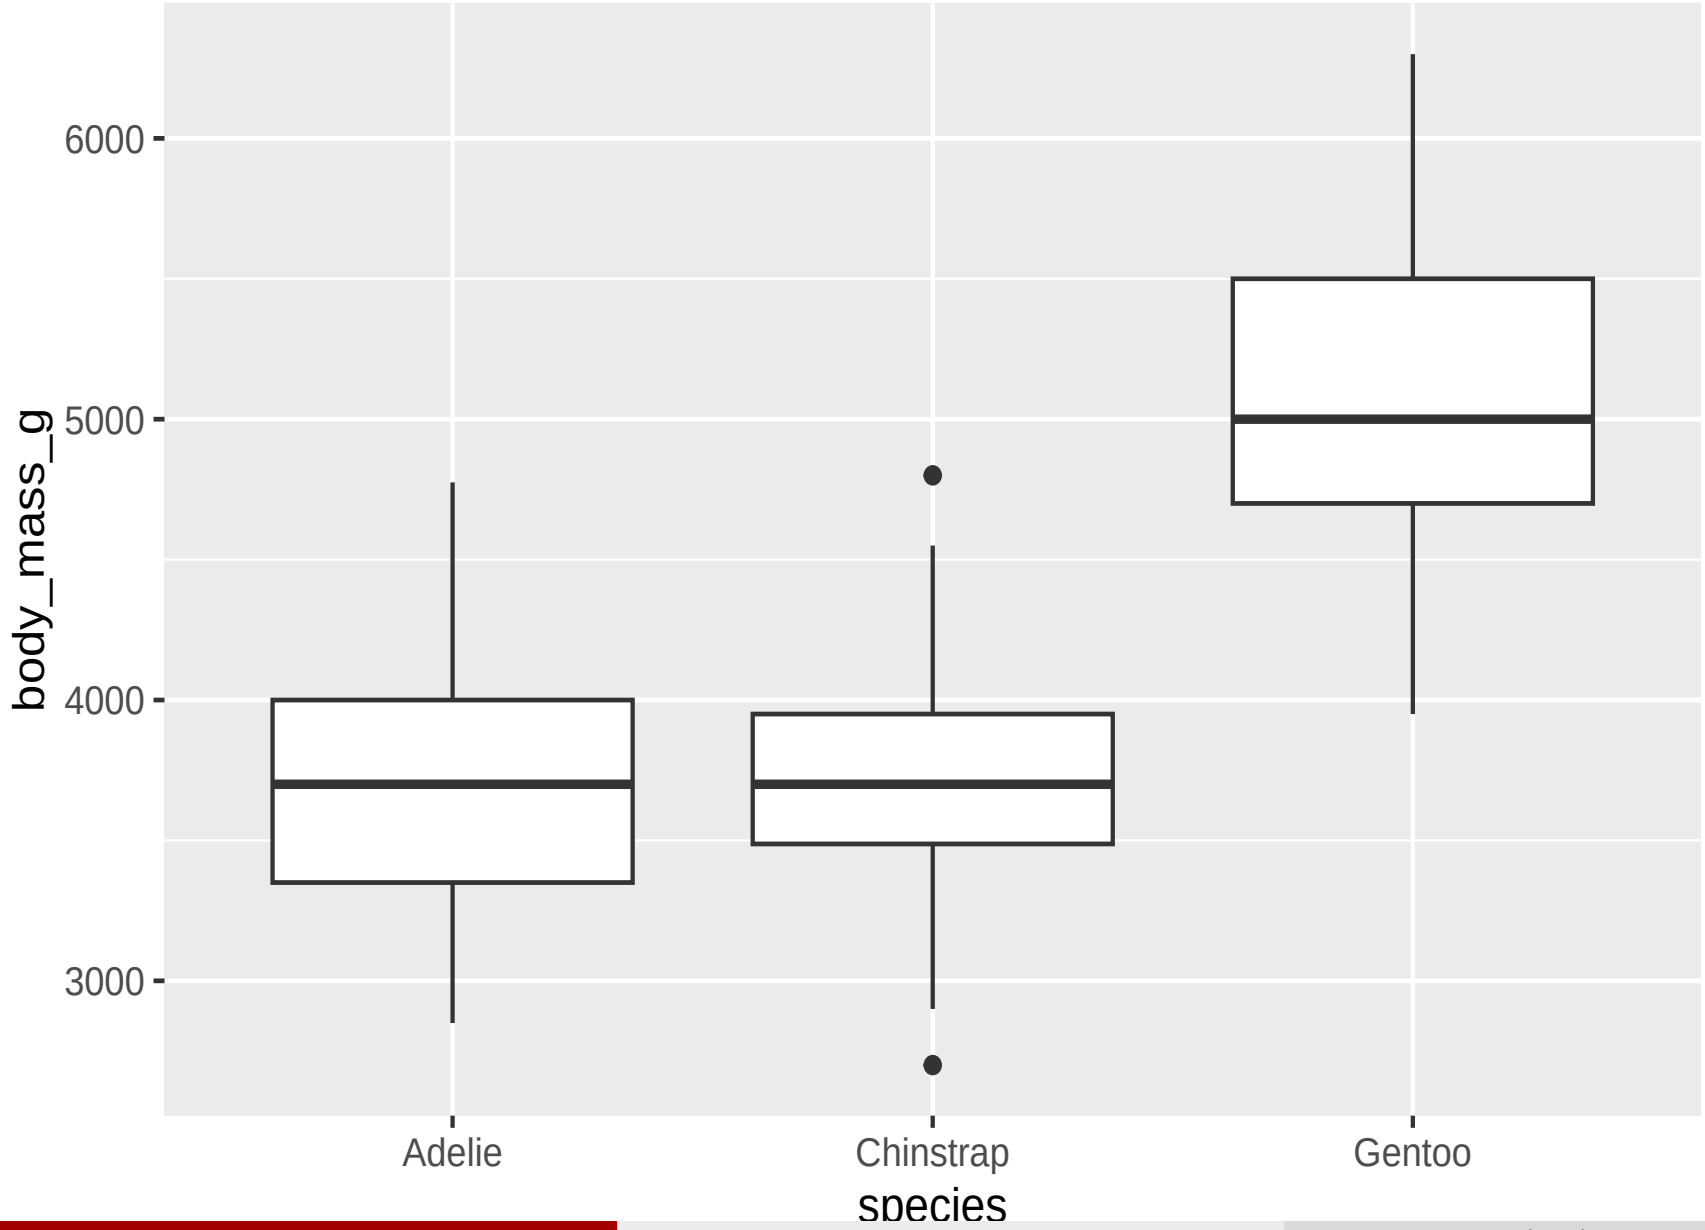

Boxplot de la masa corporal por especie

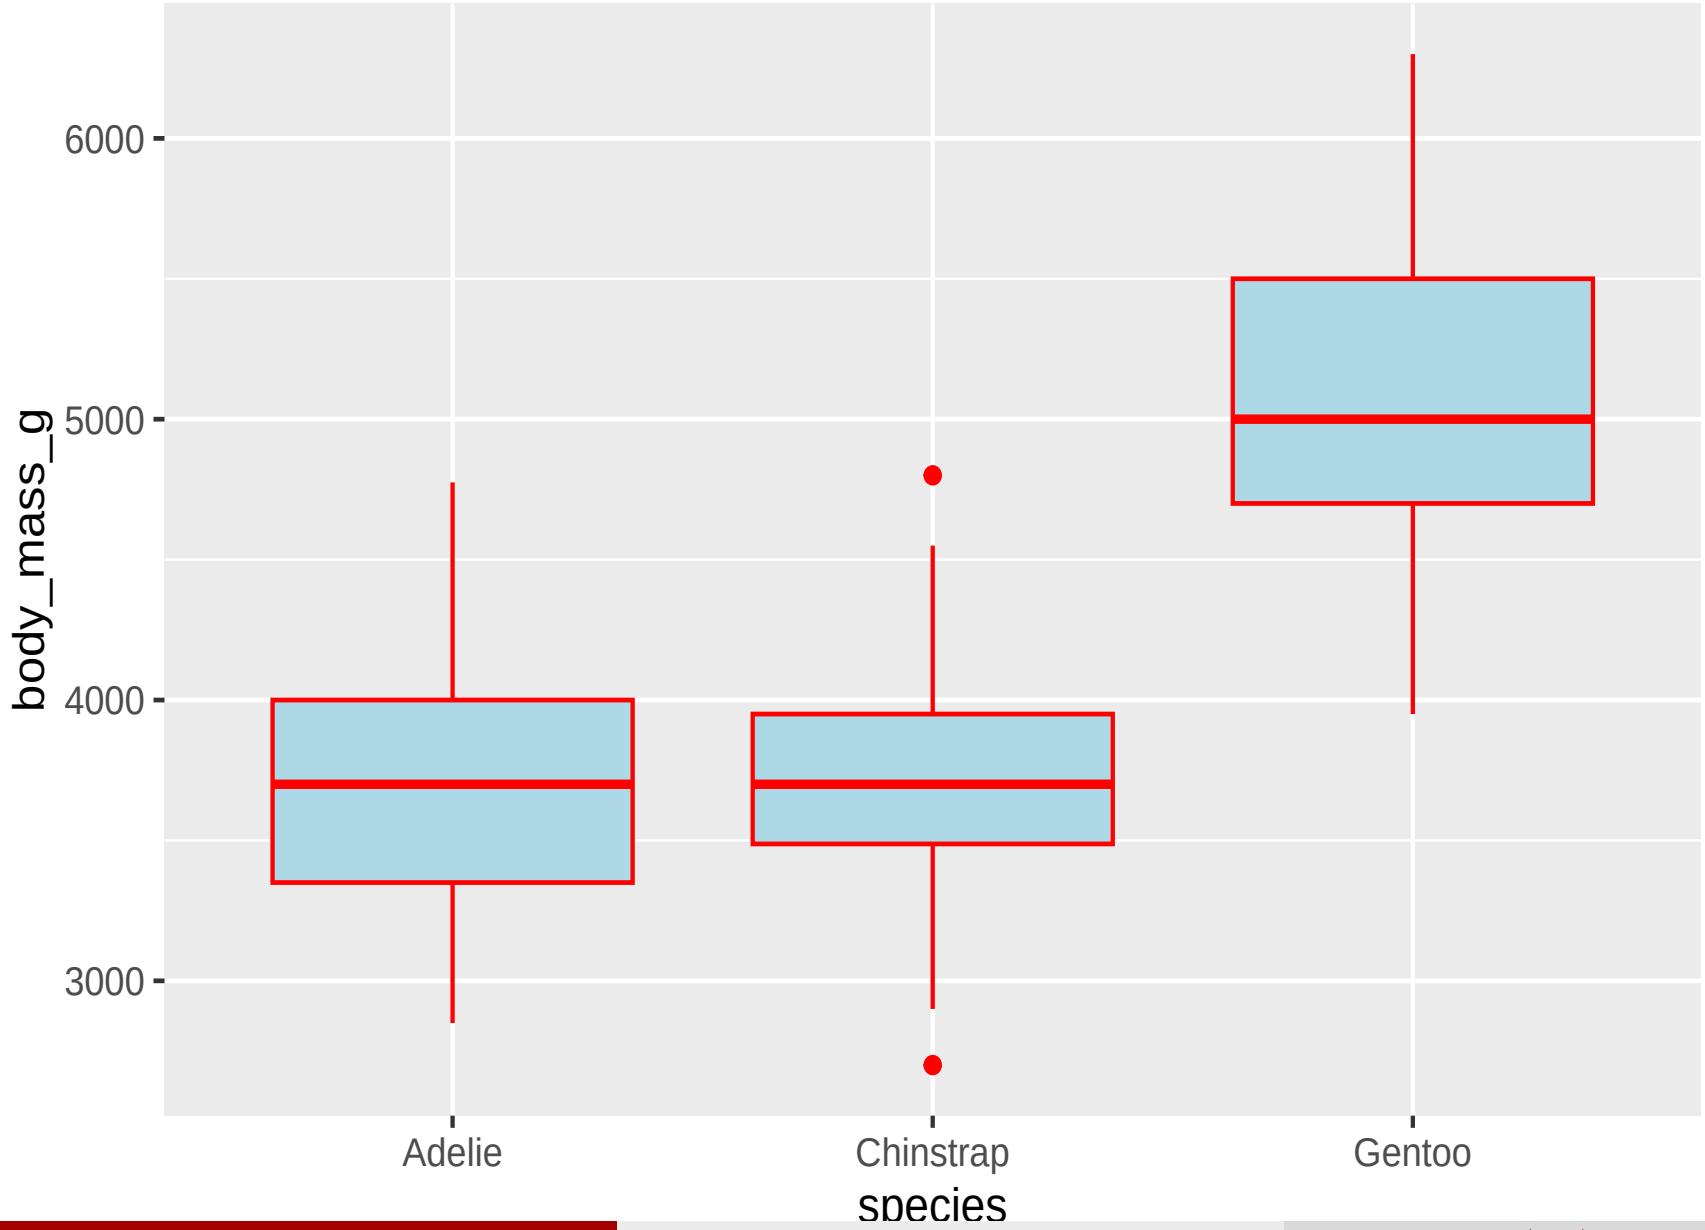

Gráfico de densidad

Alternativamente, podemos hacer gráficos de densidad con `geom_density()`:

```
ggplot(penguins,aes(x=body_mass_g,color=species)) +
geom_density(linewidth = 0.75)
```

Gráfico de densidad

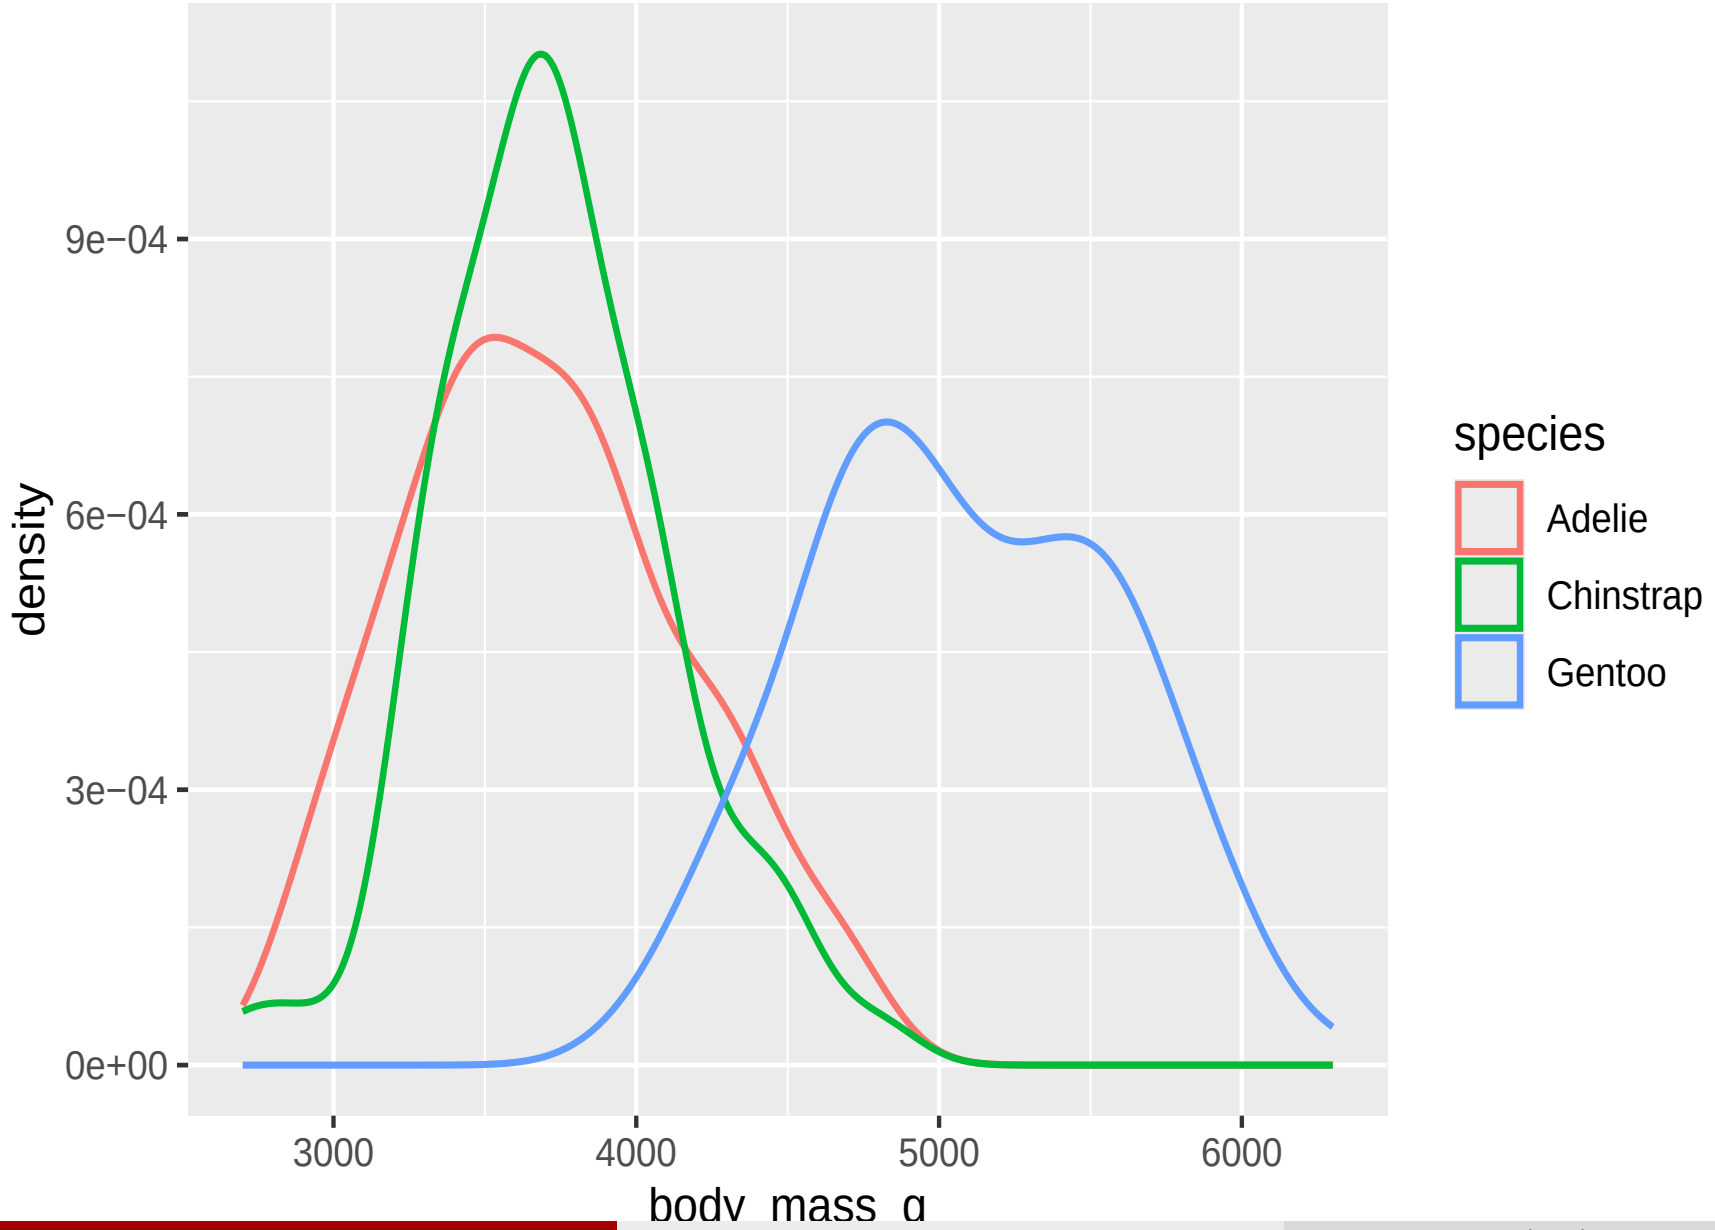

Gráfico de densidad

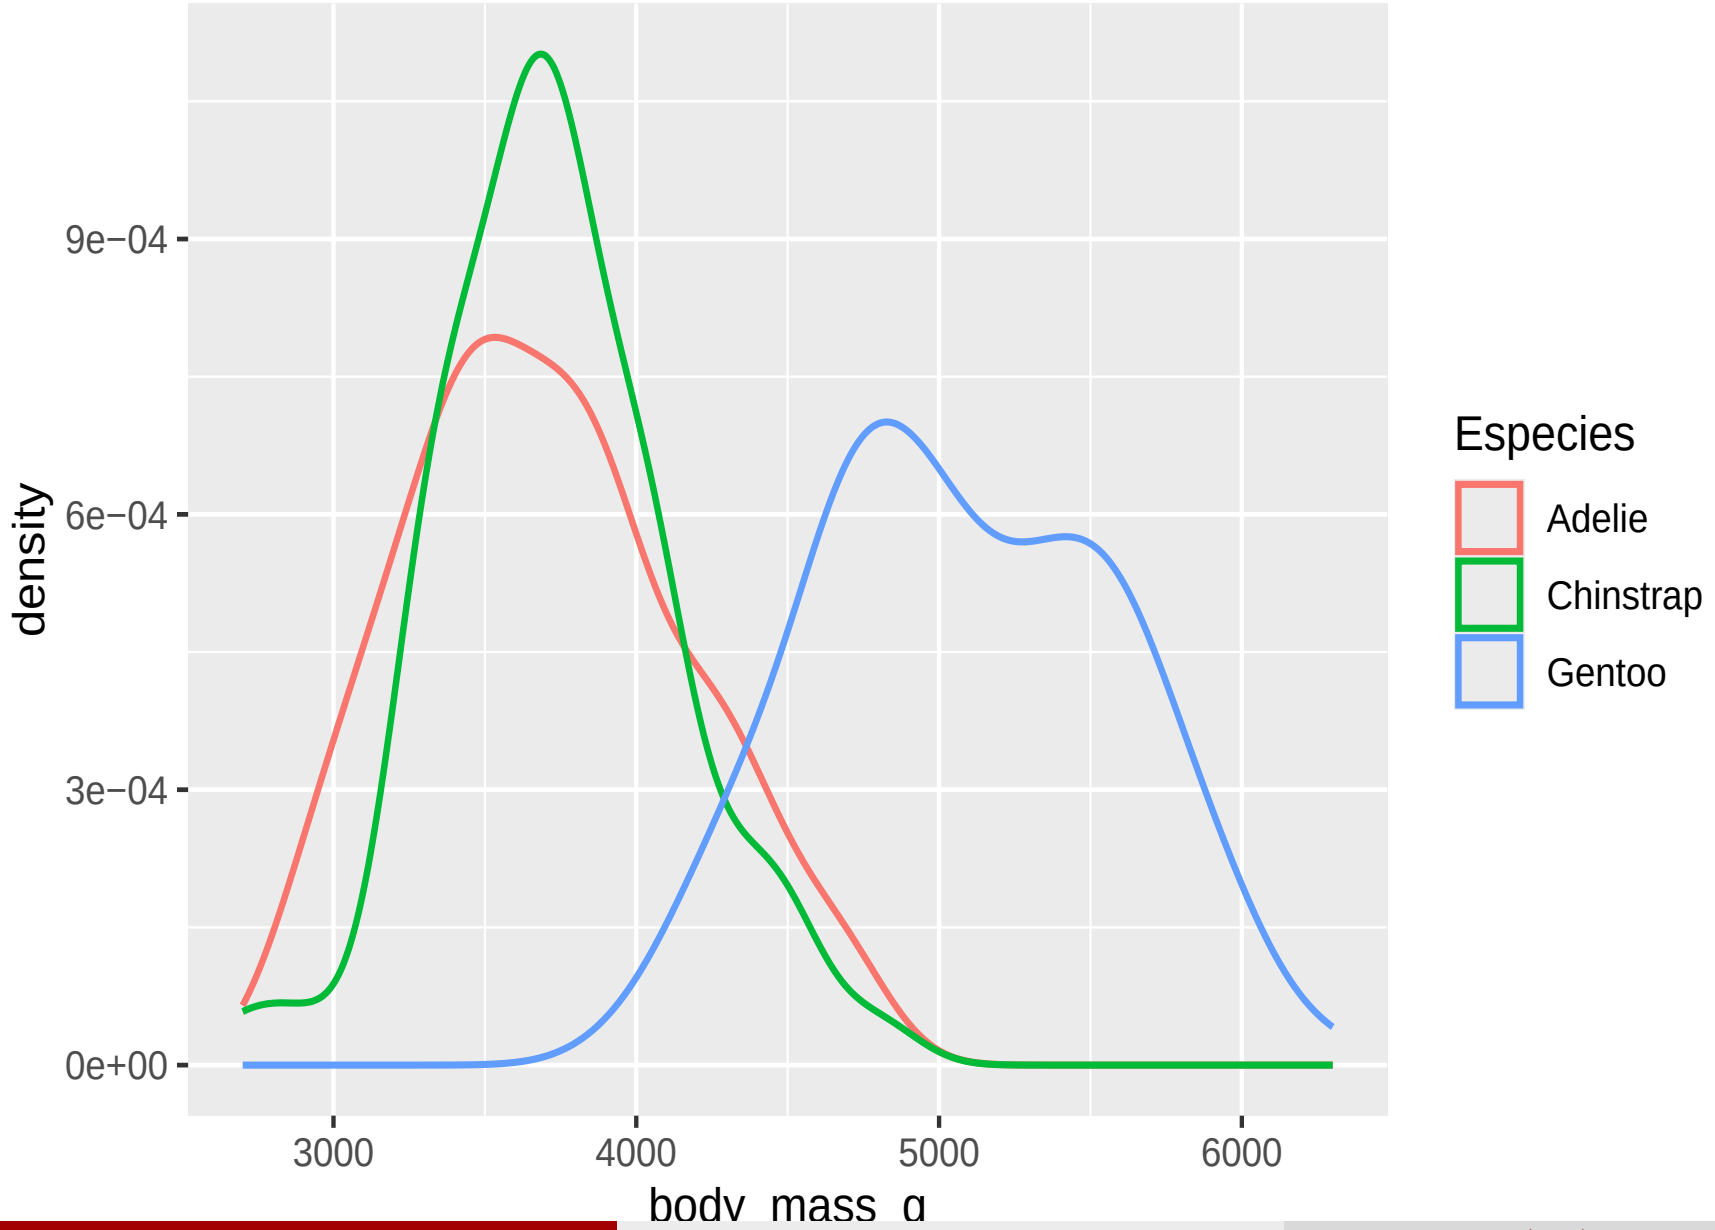

Gráfico de densidad

```
ggplot(penguins,aes(x =body_mass_g,color=species)) +
  geom_density(linewidth = 0.75) +
  labs(color="Especies")
```

- Podemos asignar `species` a la estética `color` y `fill` (relleno) y usar la estética `alpha` para agregar transparencia a las curvas de densidad rellenas.
- Esta estética toma valores entre 0 (completamente transparente) y 1 (completamente opaco).
- En el siguiente gráfico se establece `alpha` en 0.5

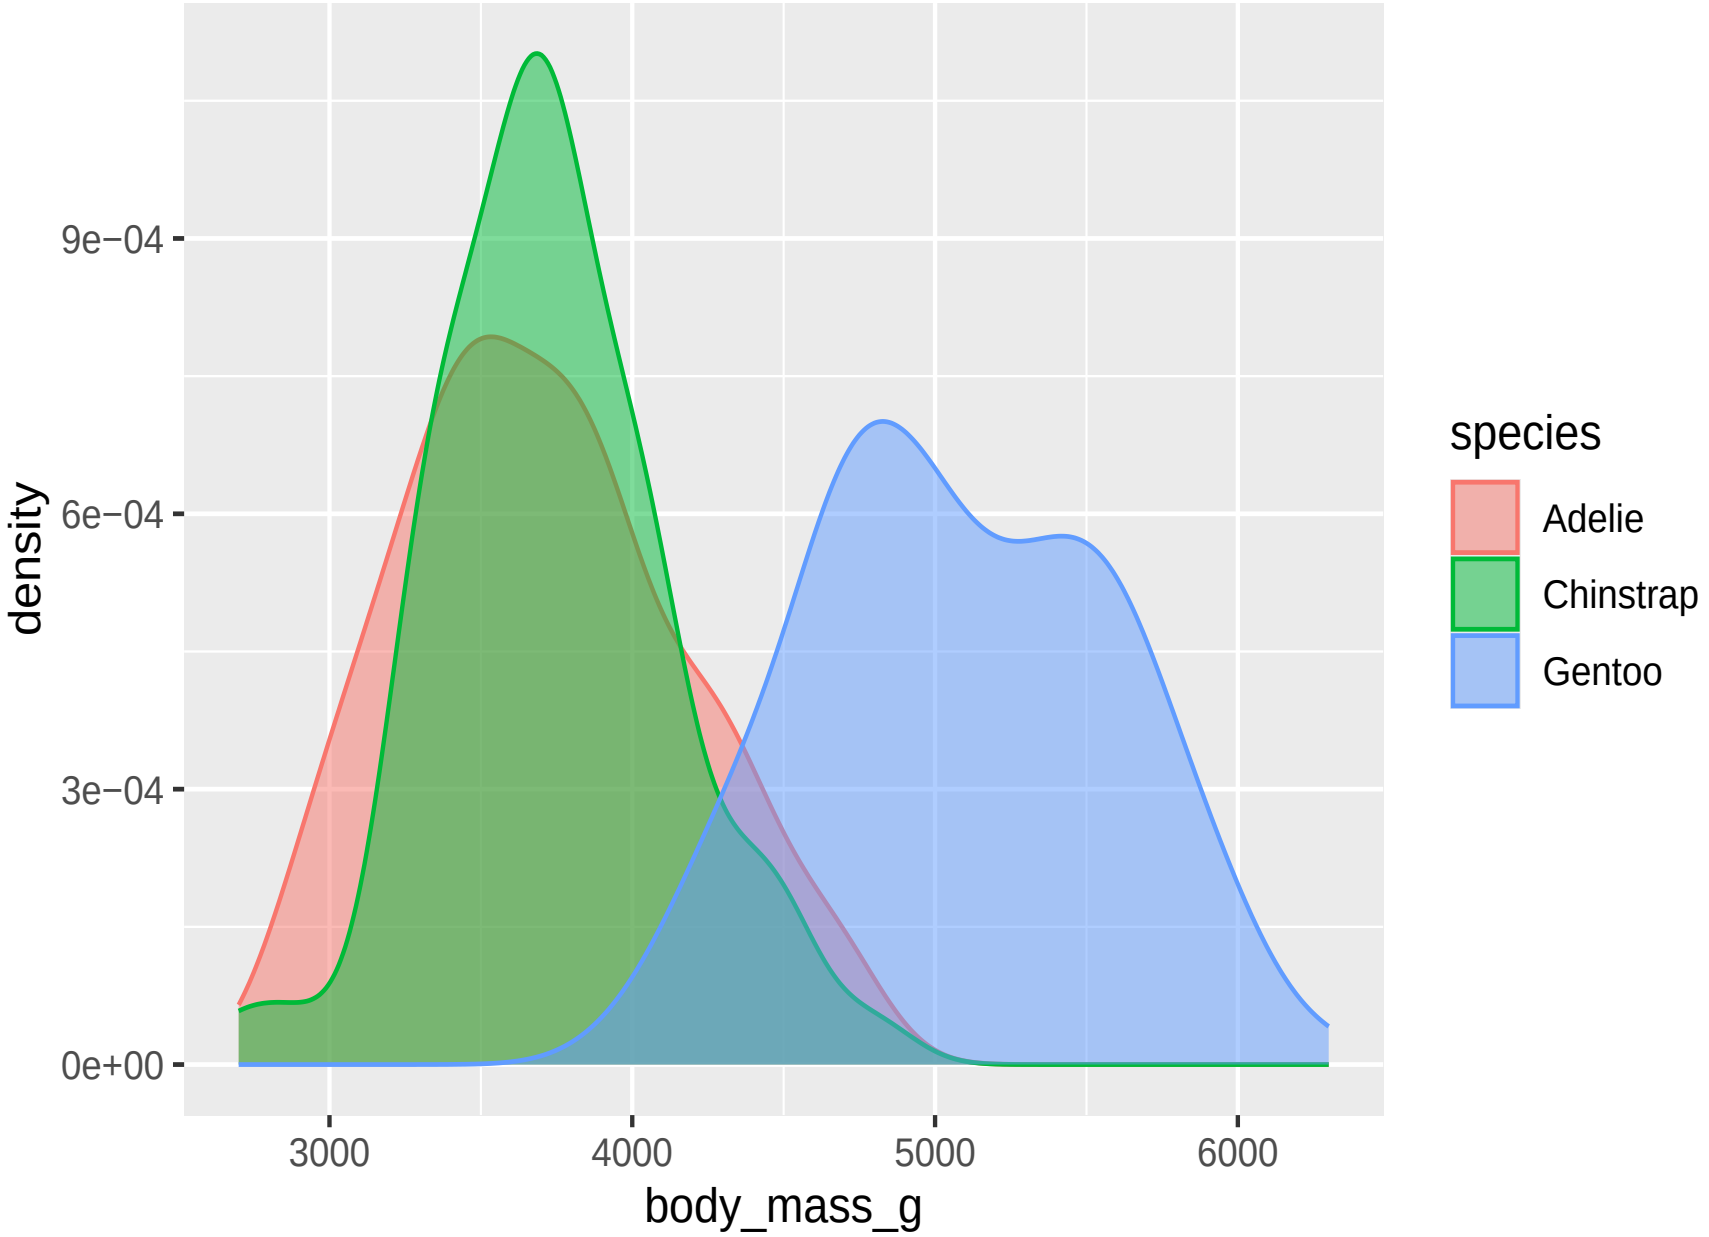
9e−04
6e−04
3e−04
0e+00
density
3000
4000
5000
6000
body_mass_g
species
Adelie
Chinstrap
Gentoo

```r
ggplot(penguins, aes(x = body_mass_g,
  color = species, fill = species)) +
geom_density(alpha = 0.5)
```

Diferencia entre ‘map’ `mapear` y ‘set’ `establecer`

Tenga en cuenta la terminología que hemos utilizado aquí:

- Mapeamos (`map`) variables a la estética si queremos que el atributo visual representado por esa estética varíe en función de los valores de esa variable.
- De lo contrario, establecemos (`set`) el valor de una estética.

Dos variables categóricas

- Podemos utilizar gráficos de barras apiladas para visualizar la relación entre dos variables categóricas.
- Por ejemplo, los siguientes dos gráficos de barras apiladas visualizan la distribución de especies dentro de cada isla.
- El primer gráfico muestra las frecuencias de cada especie de pingüino en cada isla.

Barras apiladas

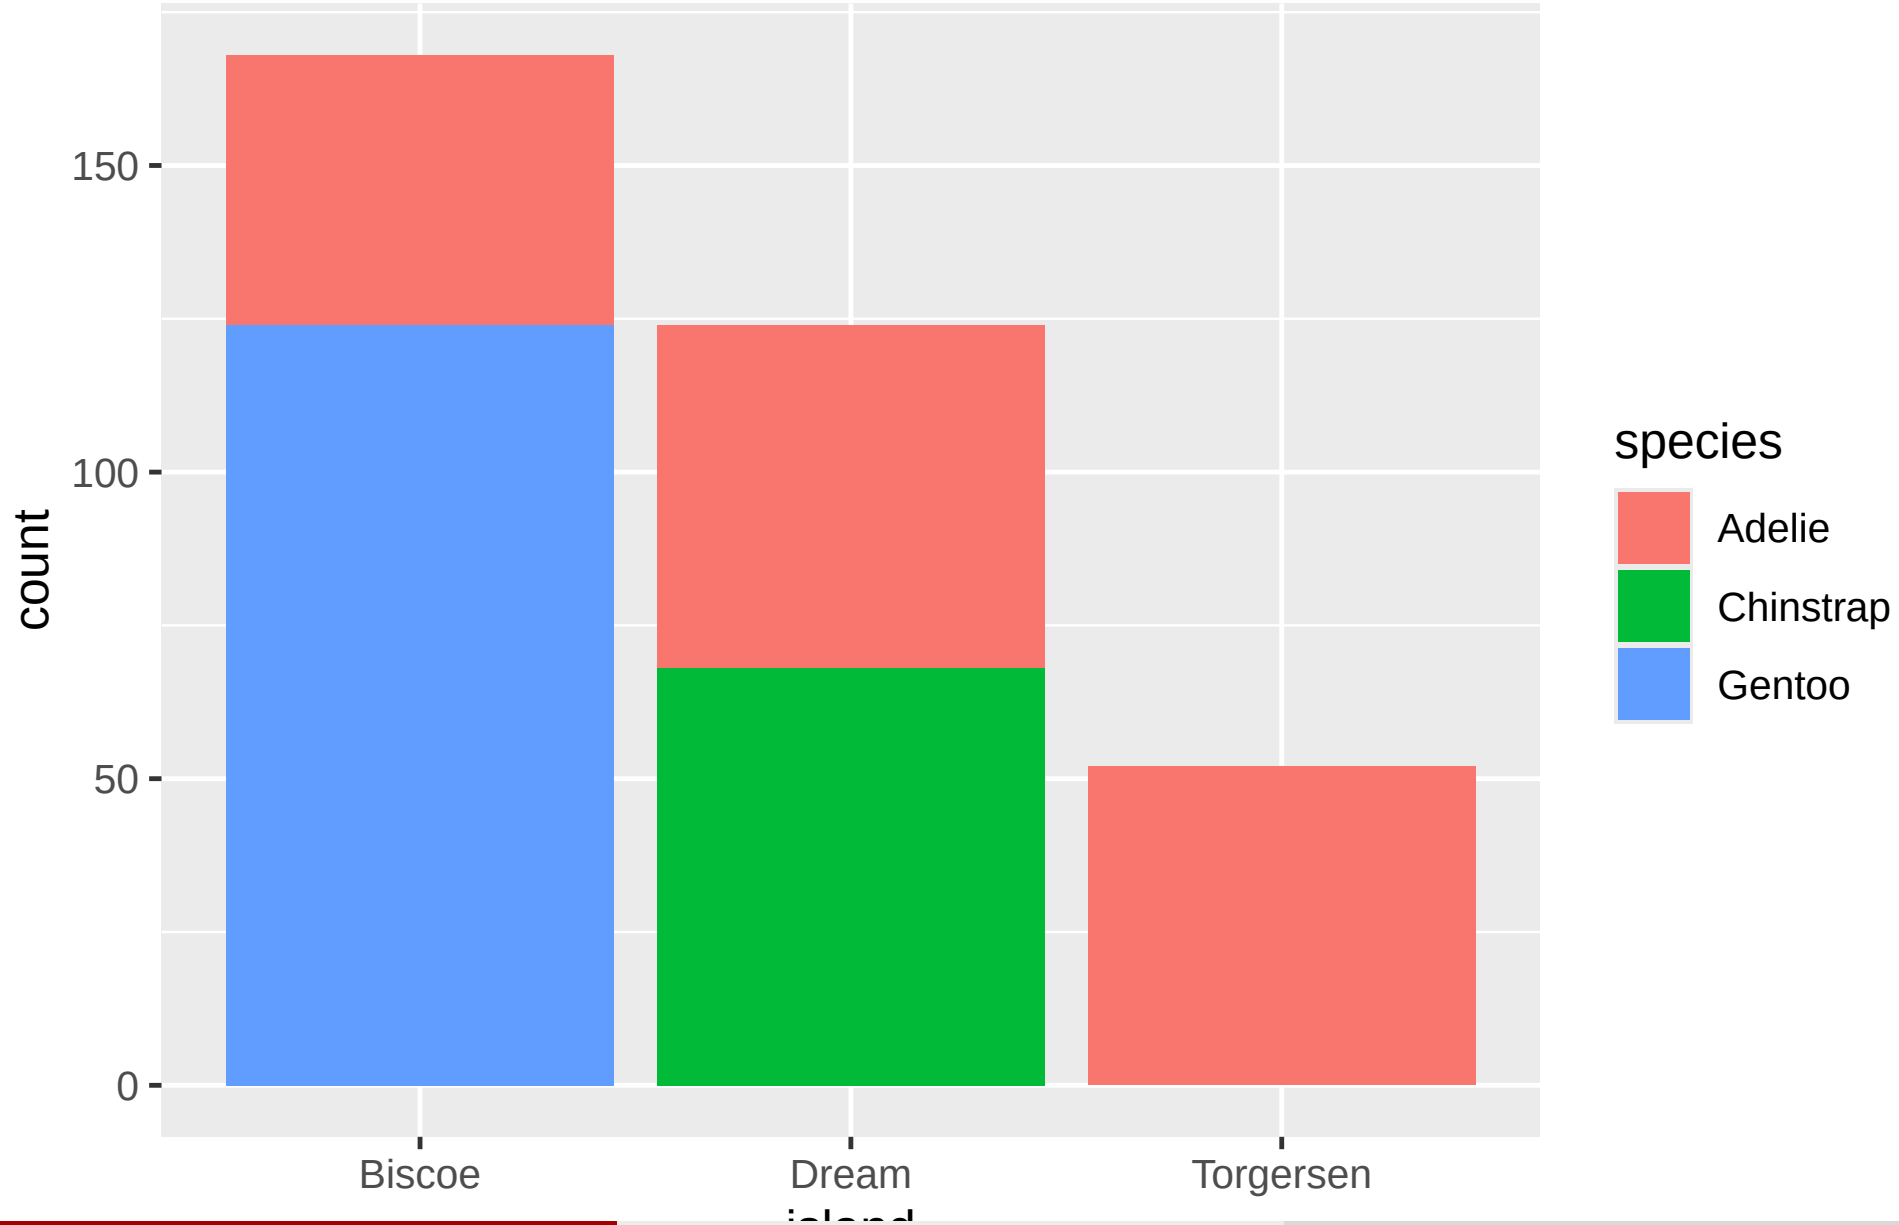

Barras apiladas código

```
ggplot(penguins, aes(x = island, fill = species)) +
  geom_bar()
```

Comentario

- El gráfico de frecuencias muestra que hay un número igual de pingüinos `Adelies` en cada isla, pero no tenemos una buena idea del equilibrio porcentual dentro de cada isla.

Gráfico de frecuencias relativas

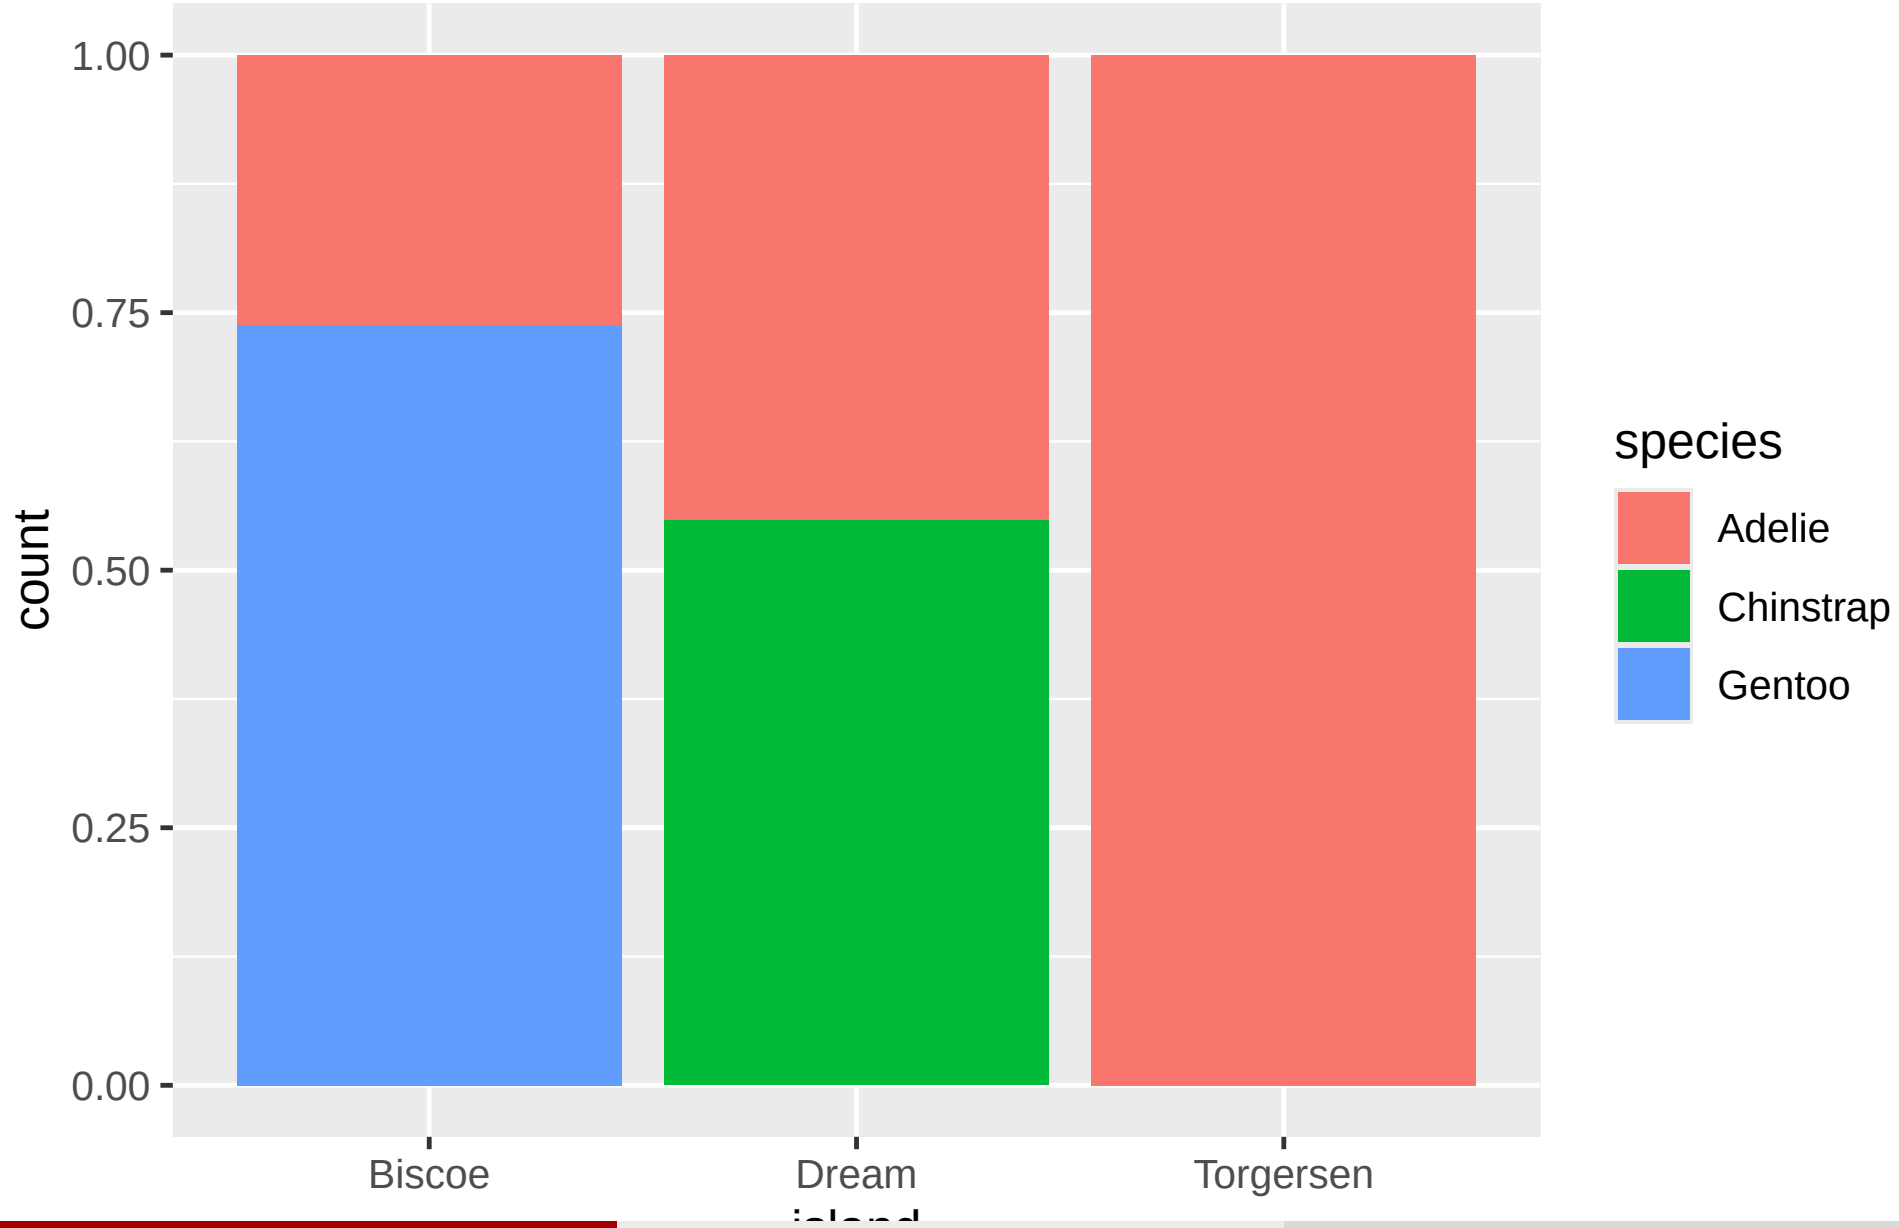

Gráfico de frecuencias relativas, código

```
ggplot(penguins,aes(x = island,fill = species)) +
      geom_bar(position='fill')
```

Gráfico de frecuencias relativas, código

```
ggplot(penguins,aes(x = island,fill = species)) +
    geom_bar(position='fill') +
    labs(y="Frecuencia relativa",
         fill="Especie")
```

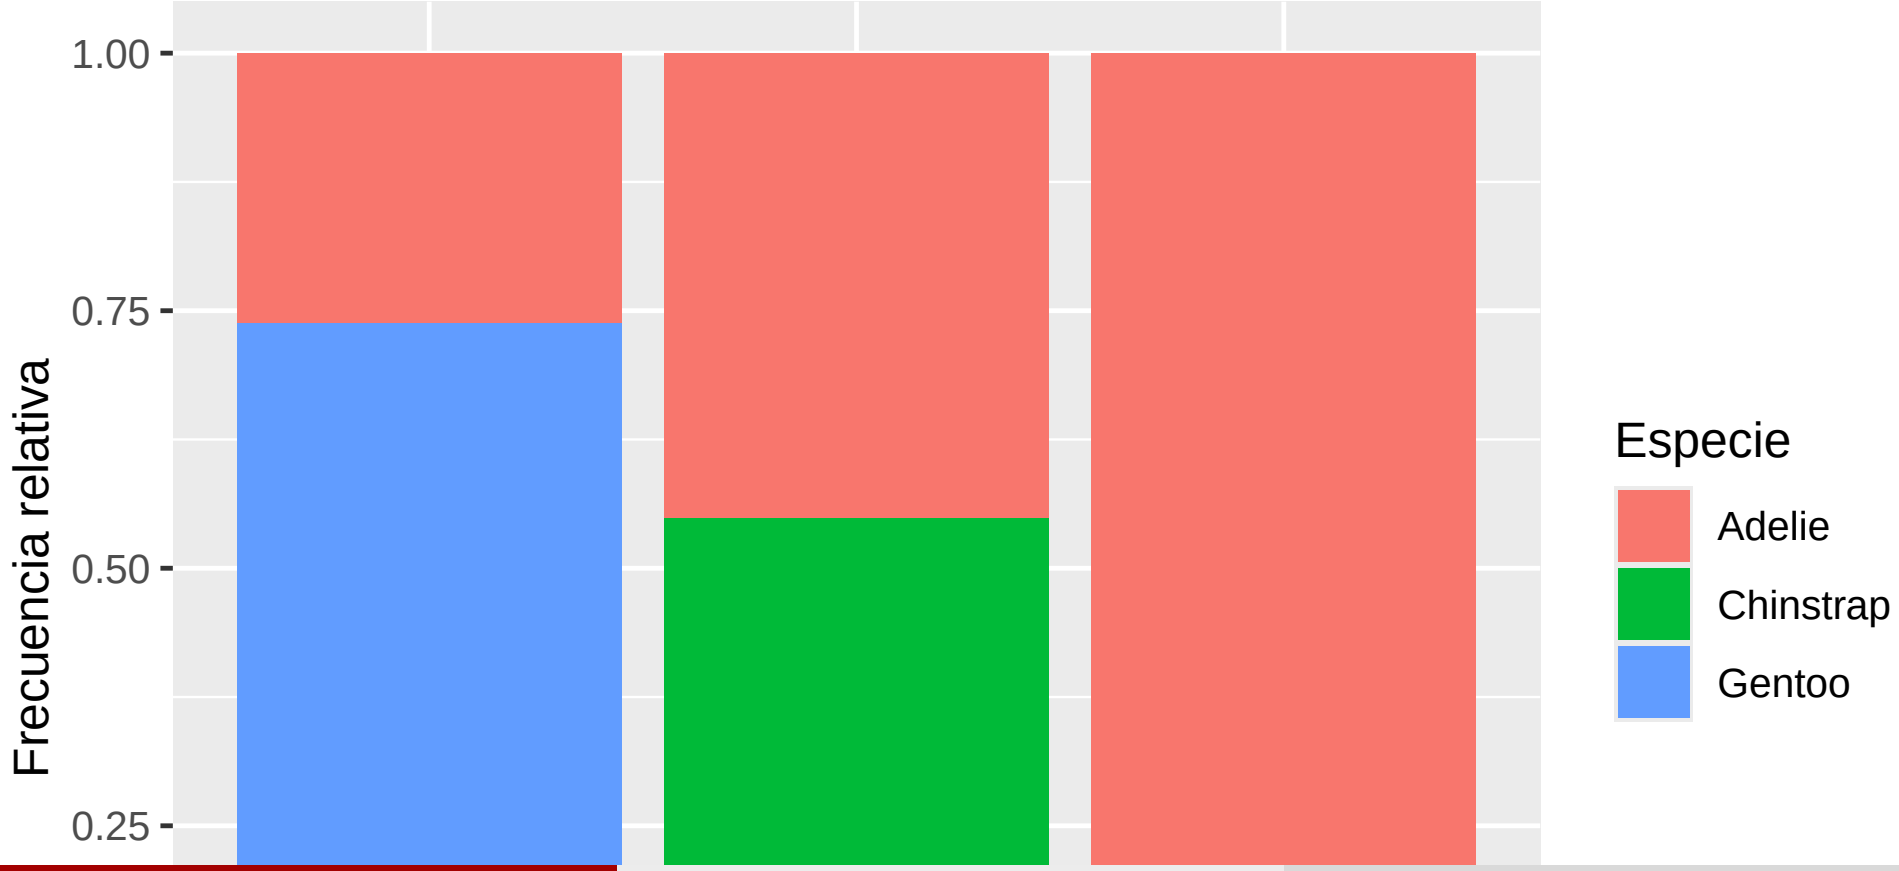

Ejercicio

El conteo dentro de la barra relativa:

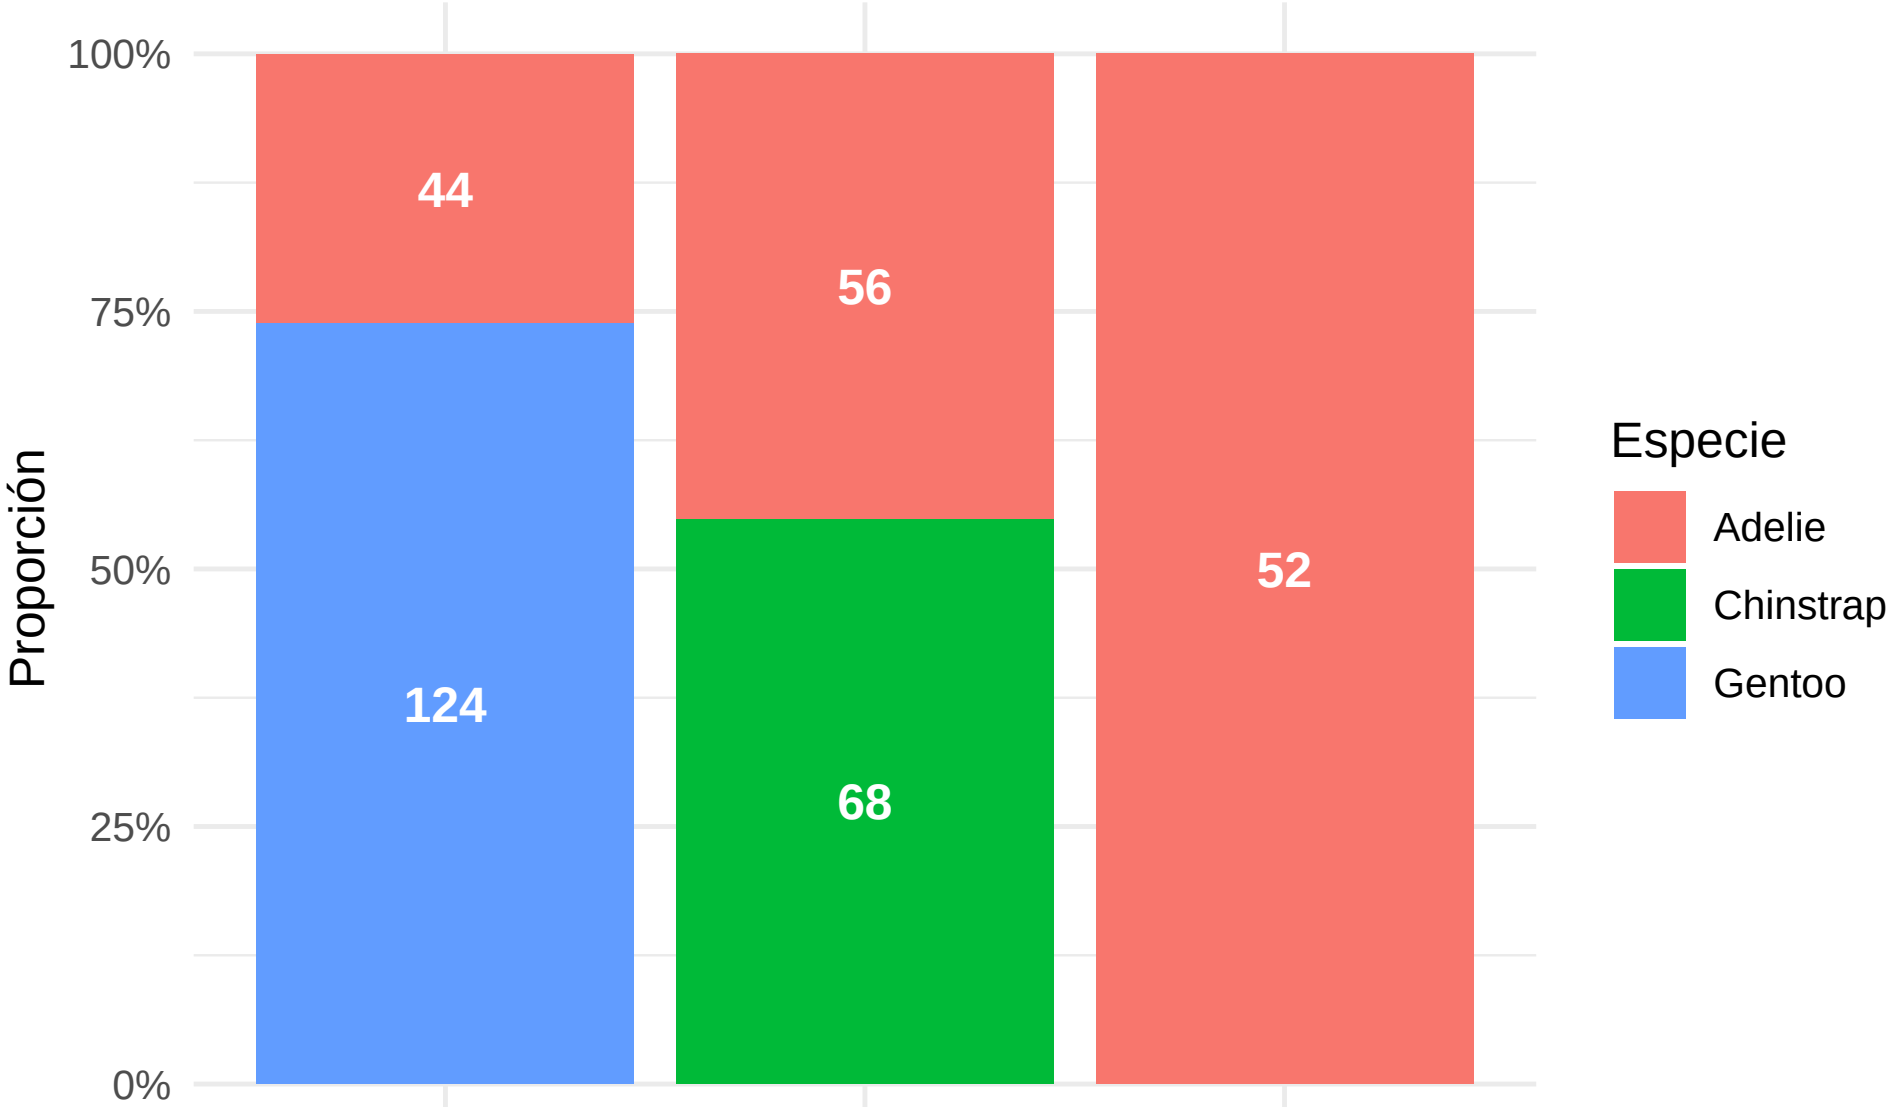

Análisis

- El gráfico de frecuencia relativa es más útil para comparar distribuciones de especies entre islas, ya que no se ve afectado por el número desigual de pingüinos en las islas.
- Usando este gráfico podemos ver que los pingüinos `Gentoo` viven todos en la isla Biscoe y representan aproximadamente el 75% de los pingüinos en esa isla.
- Los pingüinos `Chinstrap` viven todos en la isla `Dream` y representan aproximadamente el 50% de los pingüinos en esa isla,
- Los pingüinos `Adelie` viven en las tres islas y representan todos los pingüinos en Torgersen.

Dos variables numéricas

- Hasta ahora has aprendido sobre diagramas de dispersión (creados con `geom_point()`) y curvas suaves (creadas con `geom_smooth()`) para visualizar la relación entre dos variables numéricas.
- Un diagrama de dispersión es probablemente el gráfico más comúnmente utilizado para visualizar la relación entre dos variables numéricas.

Gráfico de dispersión

```
ggplot(penguins, aes(x = flipper_length_mm, y = body_mass_g))
  + geom_point()
```

Gráfico de dispersión

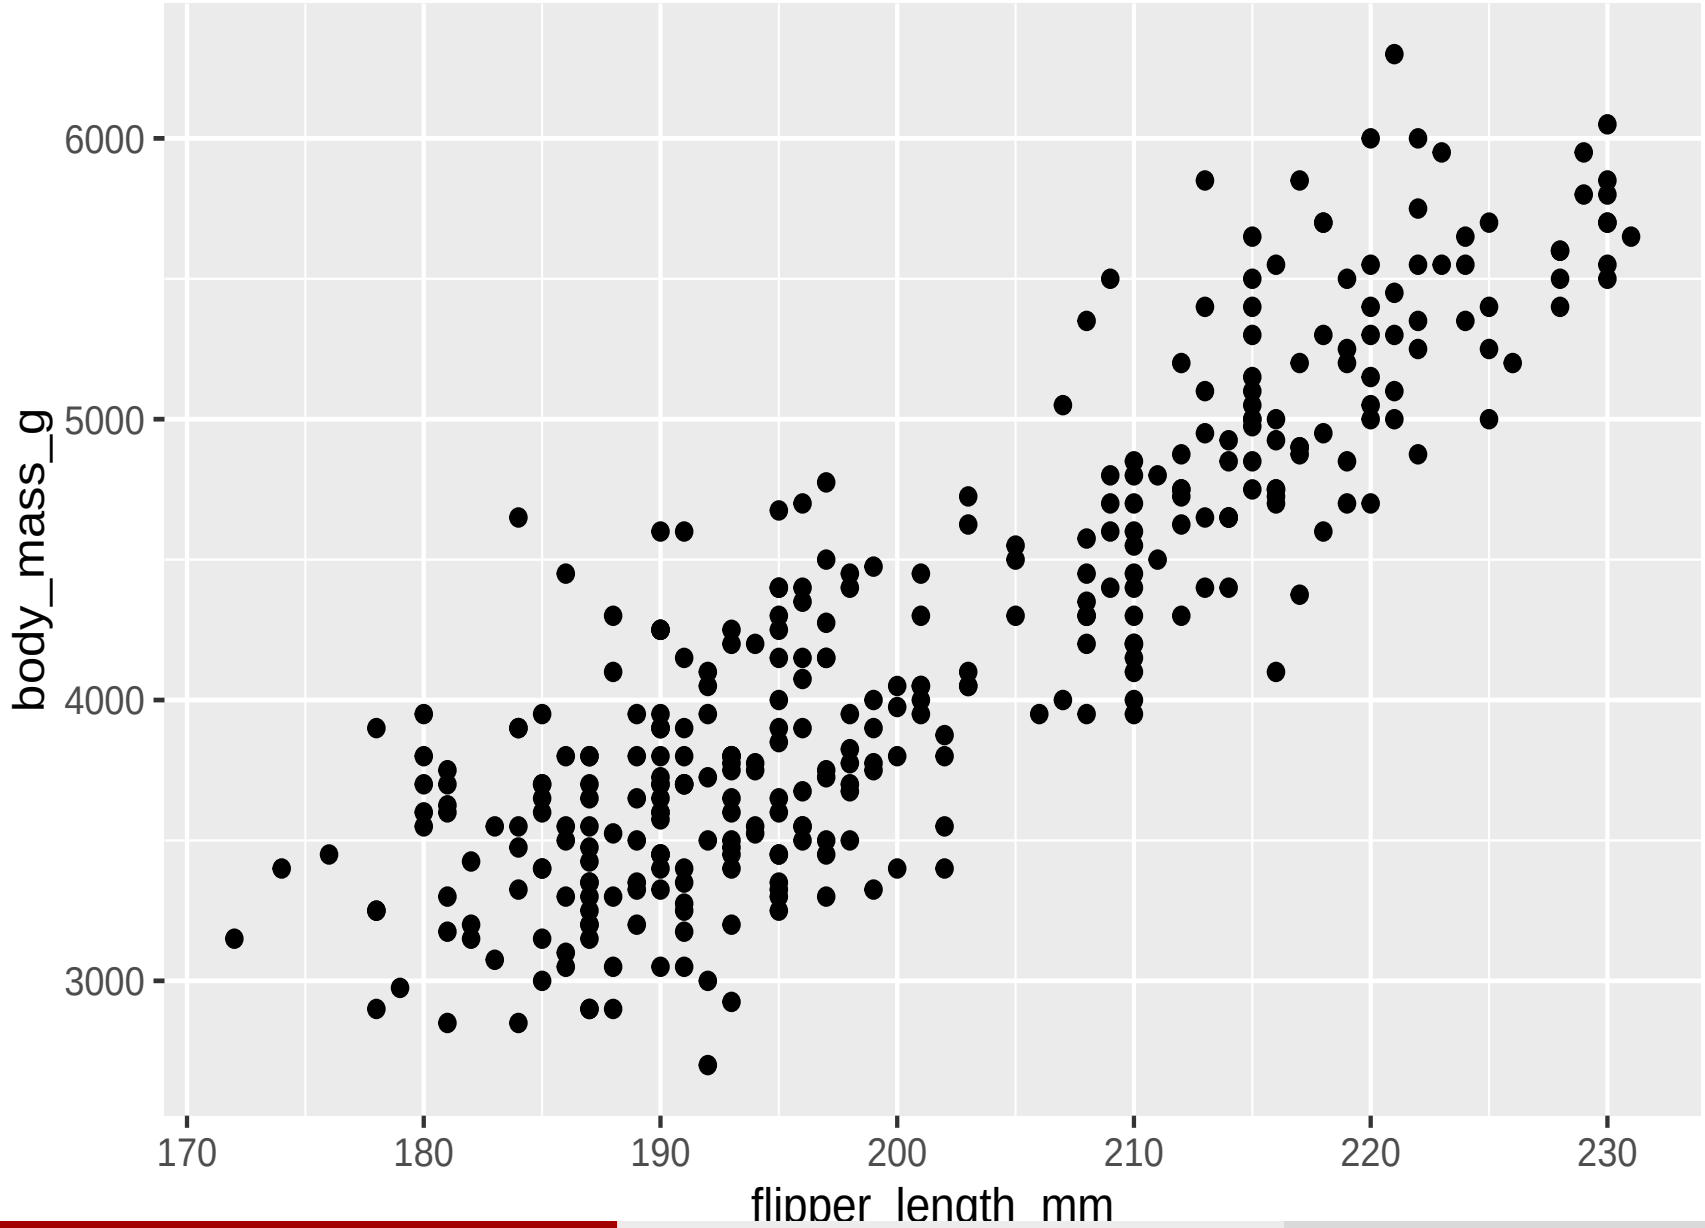

Tres o más variables

- Podemos incorporar más variables a un gráfico al asignarles una estética adicional.
- Por ejemplo, en el siguiente diagrama de dispersión los colores de los puntos representan especies y las formas de los puntos representan islas:

```
ggplot(penguins,aes(x = flipper_length_mm, y=body_mass_g))
  + geom_point(aes(color=species,
                   shape=island))
```

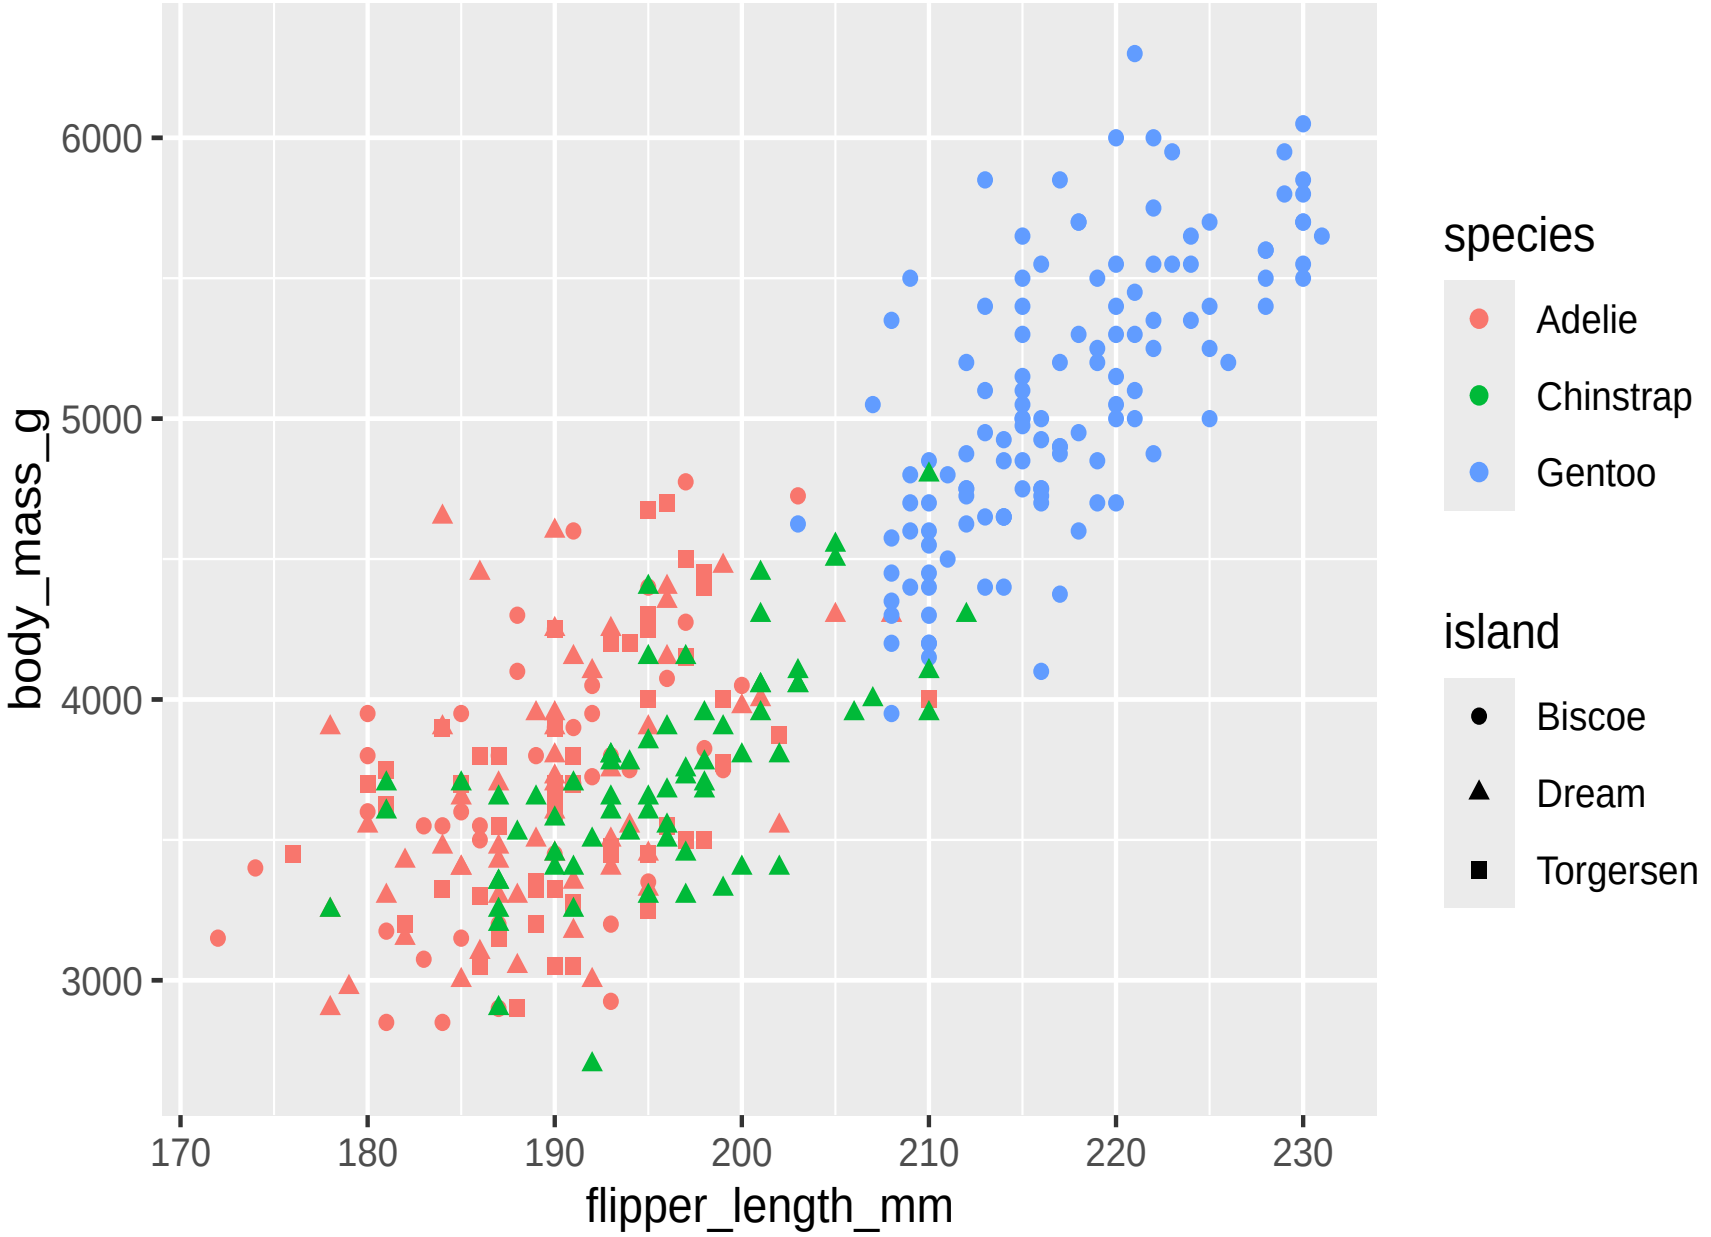
6000
5000
4000
3000
body_mass_g
170
180
190
200
210
220
230
flipper_length_mm
species
Adelie
Chinstrap
Gentoo
island
Biscoe
Dream
Torgersen

Separar el gráfico en `facets`

- Sin embargo, añadir demasiados mapeos estéticos a un gráfico lo vuelve desordenado y difícil de entender.
- Otra opción, que es particularmente útil para las variables categóricas, es dividir el gráfico en `facets`, subgráficos que muestran en cada gráfico un subconjunto de los datos.
- Para dividir el gráfico mediante una sola variable, utilice `facet_wrap()`.
- El primer argumento de `facet_wrap()` es una fórmula que se crea con ~ seguido de un nombre de variable.
- La variable que pase a `facet_wrap()` debe ser categórica.

facet_wrap()

```
ggplot(penguins,aes(x=flipper_length_mm, y=body_mass_g))
  + geom_point(aes(color=species,shape=species))
  + facet_wrap(~island)
```

facet_wrap()

Biscoe
Dream
Torgersen
6000
5000
4000
3000
body_mass_g
170180190200210220230
flipper_length_mm
species
Adelie
Chinstrap
Gentoo

Ejercicios

- En el gráfico anterior las islas están organizadas por filas (una al lado de la otra), como se hace para organizarlas por columnas (una debajo de la otra)
- Haz un diagrama de dispersión de `bill_depth_mm` versus `bill_length_mm` y colorea los puntos por especie.
  - ¿Qué revela la adición de color por especie sobre la relación entre estas dos variables?
  - ¿Qué pasa con `facet_wrap` por especie?

Ejercicio

- ¿Por qué el siguiente código produce dos leyendas separadas? ¿Cómo lo arreglarías para combinar las dos leyendas?

```
ggplot(data = penguins,mapping = aes(
x = bill_length_mm, y = bill_depth_mm,
color = species, shape = species)) +
geom_point() + labs(color = "Species")
```

Ejercicios

- Cree los dos gráficos de barras apiladas siguientes.
  - ¿Qué pregunta puedes responder con el primero?
  - ¿Qué pregunta puedes responder con el segundo?

```
ggplot(penguins, aes(x = island, fill = species)) +
geom_bar(position = "fill")
ggplot(penguins, aes(x = species, fill = island)) +
geom_bar(position = "fill")
```

Guardar los gráficos

- Una vez que hayas creado un gráfico, es posible que quieras guardarlo como una imagen que puedas usar en otra aplicación.
- Eso se hace con la función `ggsave()`, que guarda el último gráfico creado en el disco:

```
ggplot(penguins, aes(x = flipper_length_mm, y = body_mass_g))

ggsave(filename = "penguin-plot.png")
```